南 开 大 学

本 科 生 毕 业 论 文（设 计）

中文题目：**面向扰动环境下的水下场景新视角合成**

外文题目：Novel View Synthesis for Underwater Scenes in Perturbed Environments

学　　号：2213624

姓　　名：申祖铭

年　　级：2022 级

专　　业：计算机科学与技术

系　　别：计算机科学与技术

学　　院：计算机学院

指导教师：李重仪　教授

完成日期：2026 年 5 月

关于南开大学本科生毕业论文（设计）的声明

本人郑重声明：所呈交的学位论文，是本人在指导教师指导下，进行研究工作所取得的成果。除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人创作的、已公开发表或没有公开发表的作品内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。本学位论文原创性声明的法律责任由本人承担。

学位论文作者签名：

年　　月　　日

本人声明：该学位论文是本人指导学生完成的研究成果，已经审阅过论文的全部内容，并能够保证题目、关键词、摘要部分中英文内容的一致性和准确性。

学位论文指导教师签名：

年　　月　　日

摘 要

随着深度学习技术在计算机视觉领域的快速发展，三维场景重建技术经历了从传统多视图几何到神经辐射场（Neural Radiance Fields, NeRF）的范式转变。三维高斯溅射（3D Gaussian Splatting, 3DGS）作为新兴的实时辐射场渲染技术，以其高效的训练速度和实时渲染能力受到广泛关注。然而，现有方法主要针对空气中的静态场景，对水下环境的特殊物理特性考虑不足，也难以处理动态场景。

该文提出将 SeaSplat 的水下物理建模技术迁移至 4DGaussians 动态场景重建框架，构建能够同时处理水下光学退化与动态场景变化的统一重建系统。主要工作包括：（1）将基于物理的水下成像模型（衰减网络、后向散射网络及相关损失函数）嵌入动态场景重建流程；（2）引入基于 Depth Anything V2 的单目深度监督机制，提升几何一致性；（3）设计分阶段训练策略，通过参数冻结与突发更新缓解梯度冲突。实验结果表明，该方法在 Robot、Fish、Coral、Streaks 四个动态水下场景上平均峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）达 30.54 dB，较 UDR-GS 提升 1.6%，较 4DGaussians 提升 3.1%，在 Coral 场景达 33.29 dB，验证了三组件的互补性与方法的有效性。

关键词：三维高斯溅射 (3DGS)；水下场景重建；动态场景建模；物理成像模型；深度监督

Abstract

With the rapid advancement of deep learning in computer vision, 3D scene reconstruction has evolved from traditional multi-view geometry to Neural Radiance Fields (NeRF). 3D Gaussian Splatting (3DGS), as an emerging real-time radiance field rendering technique, has attracted considerable attention for its efficient training and real-time rendering capabilities. However, existing methods primarily target static aerial scenes and insufficiently address the unique physical properties of underwater environments, while also struggling with dynamic scenes.

This work proposes migrating SeaSplat's underwater physical modeling into the 4DGaussians dynamic scene reconstruction framework, building a unified system capable of simultaneously handling underwater optical degradation and dynamic scene changes. The main contributions include: (1) embedding a physics-based underwater imaging model (attenuation network, backscatter network, and associated loss functions) into the dynamic reconstruction pipeline; (2) introducing monocular depth supervision based on Depth Anything V2 to improve geometric consistency; (3) designing a staged training strategy that mitigates gradient conflicts through parameter freezing and burst updates. Experimental results demonstrate that the proposed method achieves an average Peak Signal-to-Noise Ratio (PSNR) of 30.54 dB across four dynamic underwater scenes (Robot, Fish, Coral, and Streaks), surpassing UDR-GS by 1.6% and 4DGaussians by 3.1%, with 33.29 dB on the Coral scene, validating the complementarity of the three components and the effectiveness of the approach.

Key Words: 3D Gaussian splatting; underwater scene reconstruction; dynamic scene modeling; physical imaging model; depth supervision

目 录

摘 要 …… I
Abstract …… II
目 录 …… III
第一章 绪论 …… 1
第一节 研究背景与意义 …… 1
第二节 国内外研究现状 …… 2
1.2.1 神经辐射场与 3D Gaussian Splatting …… 2
1.2.2 水下场景重建方法 …… 2
1.2.3 动态场景重建 …… 3
1.2.4 深度监督与几何正则化 …… 3
1.2.5 技术融合趋势与研究空白 …… 4
第三节 主要研究内容与贡献 …… 4
第四节 论文组织结构 …… 5
第二章 相关技术基础 …… 6
第一节 3D Gaussian Splatting 基础 …… 6
2.1.1 场景表示 …… 6
2.1.2 可微光栅化渲染 …… 7
2.1.3 自适应密度控制 …… 8
第二节 水下图像成像模型 …… 8
2.2.1 光在水中的传播特性 …… 8
2.2.2 修正水下图像形成模型 …… 9
2.2.3 暗通道先验 …… 9
第三节 SeaSplat 水下建模方法 …… 10
2.3.1 BackscatterNet 网络 …… 10
2.3.2 AttenuateNet 网络 …… 10
2.3.3 水下损失函数 …… 11
第四节 4DGaussians 动态重建方法 …… 12
2.4.1 时间维度扩展 …… 12
2.4.2 HexPlane 多分辨率时空网格 …… 12
2.4.3 变形网络架构 …… 13

2.4.4 两阶段训练策略 ····· 13
第五节 单目深度估计 ····· 14
第三章 系统设计与实现 ····· 15
第一节 总体框架设计 ····· 15
3.1.1 设计思路 ····· 15
3.1.2 系统架构 ····· 16
第二节 SeaSplat 水下模块迁移 ····· 16
3.2.1 代码框架差异分析 ····· 16
3.2.2 核心模块迁移 ····· 17
3.2.3 渲染流程修改 ····· 18
第三节 单目深度监督实现 ····· 18
3.3.1 深度图生成流程 ····· 18
3.3.2 监督机制 ····· 19
第四节 分阶段训练策略 ····· 20
3.4.1 粗训练阶段 ····· 20
3.4.2 精细阶段初始化 ····· 20
3.4.3 背散射/衰减预热阶段 ····· 21
3.4.4 高斯颜色调整阶段 ····· 21
3.4.5 联合训练与突发更新阶段 ····· 21
第五节 稳定性优化 ····· 22
3.5.1 GT 图像 CUDA 错误保护 ····· 22
3.5.2 单目深度 NaN 值清理 ····· 22
3.5.3 精细阶段恢复训练修复 ····· 23
3.5.4 渲染过程 CUDA 保护 ····· 23
第六节 关键配置参数 ····· 23
第七节 本章小结 ····· 25
第四章 实验结果与分析 ····· 26
第一节 实验设置 ····· 26
4.1.1 实验环境 ····· 26
4.1.2 数据集 ····· 26
4.1.3 评估指标 ····· 27
4.1.4 对比方法 ····· 27
第二节 动态场景实验结果 ····· 28

4.2.1 PSNR 定量对比 ····· 28
4.2.2 多指标综合对比 ····· 29
第三节 对比分析 ····· 29
4.3.1 与 SeaSplat 对比分析 ····· 29
4.3.2 与 4DGS 和 UDR-GS 对比分析 ····· 30
4.3.3 技术路线差异分析 ····· 31
第四节 可视化结果 ····· 32
4.4.1 渲染效果对比 ····· 32
4.4.2 水下去水效果展示 ····· 33
4.4.3 中间产物可视化 ····· 33
第五节 消融实验 ····· 34
4.5.1 消融实验设计 ····· 34
4.5.2 定量结果 ····· 35
4.5.3 Robot 场景：完整模型协同增益的典型案例 ····· 35
4.5.4 Streaks 场景：物理模型适用边界的揭示 ····· 36
4.5.5 Coral 场景：清水条件下的 SeaThru 失稳机制 ····· 36
4.5.6 Fish 场景：小目标动态下的多模块梯度冲突 ····· 37
4.5.7 消融实验综合分析 ····· 37
第六节 讨论 ····· 38
4.6.1 三组件互补性分析 ····· 38
4.6.2 局限性分析 ····· 40
第五章 总结与展望 ····· 42
第一节 工作总结 ····· 42
第二节 创新点 ····· 43
第三节 未来工作 ····· 43
参考文献 ····· 45
参考文献 ····· 45
致 谢 ····· XLVIII
个人简历 ····· XLIX

第一章　绪论

第一节　研究背景与意义

海洋覆盖地球表面积约 71%，蕴藏着极为丰富的自然资源与科学研究价值。随着人类对深海探索需求的持续增长，水下场景的高精度三维重建与新视角合成技术已成为海洋科学、水下机器人与计算机视觉领域的重要研究方向。该技术在海洋资源勘探、水下文化遗产考古、珊瑚礁生态监测以及自主水下航行器（AUV）与遥控水下航行器（ROV）的自主导航等任务中均具有广泛的应用前景[1, 2]。

然而，水下环境与陆地大气环境存在本质差异，给三维重建任务带来了一系列独特的技术挑战。

光学衰减与色偏问题。水是一种对光具有选择性吸收特性的介质。红色波段（约 650nm）的光在水中的衰减系数远大于蓝绿色波段（约 450nm），导致图像在水下呈现出显著的蓝绿色偏色现象[3]。随着拍摄距离的增加，红色通道信息大量丢失，颜色失真日益严重，给基于多视角图像的场景外观重建造成极大困难。

散射效应。水体中悬浮的微粒（如浮游生物、有机碎屑和无机悬浮颗粒）会引发两类散射效应：前向散射使图像细节模糊，后向散射则在相机与被摄物体之间形成”雾幔”效应，使图像对比度下降，整体呈现出朦胧的外观[3]。上述散射效应在传统大气成像模型中均未被考虑，因此直接将陆地三维重建方法应用于水下场景时，其效果往往大打折扣。

动态扰动因素。除光学问题外，水下环境还面临多种动态扰动：水流引起的平台抖动、鱼类及海洋生物的自由游动、漂浮颗粒物的随机运动等，均会在多帧图像之间引入不可忽略的非刚性形变，使静态场景假设失效[4]。

上述问题相互耦合，共同构成了”扰动环境下水下场景新视角合成”的核心难题。现有的通用三维重建方法，如神经辐射场（NeRF）及三维高斯散射（3DGS），在处理水下场景时均存在明显局限。如何在统一框架下同时处理水下物理退化、动态场景变化与几何一致性问题，是本文致力于解决的核心科学问题。

第二节　国内外研究现状

1.2.1　神经辐射场与 3D Gaussian Splatting

神经辐射场（Neural Radiance Field，NeRF）由 Mildenhall 等人[5] 于 2020 年提出，通过以三维坐标和观测方向为输入的多层感知机（MLP）隐式地表达场景的体积密度与辐射颜色，结合体渲染方程生成任意视角的新视图，在新视角合成任务上取得了里程碑式的成果。此后，研究者围绕 NeRF 的质量与效率展开了大量改进工作：Mip-NeRF[6] 引入圆锥追踪与积分位置编码，有效缓解了多尺度场景中的走样问题；Instant-NGP[7] 采用多分辨率哈希编码，将训练时间从数小时压缩至数分钟；MERF[8] 利用稀疏体素网格实现实时渲染。神经辐射场方法在国内也引发了广泛关注，相关综述工作对其理论基础与应用进展进行了系统梳理[9, 10]。

三维高斯散射（3D Gaussian Splatting，3DGS）由 Kerbl 等人[11] 于 2023 年提出，是近年来新视角合成领域最具影响力的进展之一。3DGS 采用显式的三维高斯椭球体作为场景表示单元，每个高斯体携带位置、协方差、不透明度及球谐系数等属性，并通过可微分的基于排序的点云光栅化（tile-based rasterization）进行高效渲染，在单张消费级 GPU 上实现了超过 100 帧/秒的实时渲染速度，同时将训练时间缩短至数十分钟以内。

然而，3DGS 在设计时默认场景处于大气成像条件下，其渲染模型不包含水下物理退化的建模。当直接将 3DGS 应用于水下场景时，颜色通道的非均匀衰减会导致高斯体学习到错误的外观属性，渲染结果呈现明显的色彩偏差；散射效应的缺失则使高斯体倾向于在相机前方生成大量”浮空”伪影，严重影响几何重建质量。

1.2.2　水下场景重建方法

水下图像复原与三维重建长期以来是水下视觉领域的核心问题。经典工作包括：McGlamery[12] 和 Jaffe[13] 建立了早期水下成像物理模型；暗通道先验（DCP）[14] 被广泛用于水下图像去雾。

在水下成像物理模型方面，Akkaynak 和 Treibitz 提出了修正水下图像成像模型[15]，将图像信号分解为直接信号分量与后向散射分量，并分别引入波长相关的衰减系数，比传统简化模型更准确地刻画了水下光学特性。在此基础上，Sea-thru[16] 方法实现了从水下图像中自动去除水体效应，恢复真实场景颜色，为后续工作奠定了基础。

将物理模型与神经场景表示相结合是近年来的主流方向。SeaThru-NeRF[17] 首次将修正水下成像模型集成到 NeRF 框架中，通过联合优化场景辐射场与水下介质参数，实现了水下场景的高保真新视角合成，但其基于 MLP 的隐式表示导致训练与渲染速度较慢，难以满足实际应用需求。SeaSplat[18] 将水下物理模型迁移至 3DGS 框架，设计了 BackscatterNet 与 AttenuateNet 两个轻量级网络分别预测后向散射项与衰减系数，训练时间约 85 分钟，显存占用约 4GB，在渲染效率上取得了显著提升，但仍局限于静态场景处理。

近期，多项工作从不同角度进一步拓展了水下 3DGS 的研究：WaterSplatting[19] 在散射介质建模方面进行了改进；UW-GS[20] 针对水下几何精度进行了优化；SeaFree-GS[21] 探索了无物理模型先验的数据驱动方案；RecGS[22] 关注水下场景的可恢复性建模；3D-UIR[23] 从图像复原角度改善渲染质量；DualPhys-GS[24] 提出了双重物理约束机制；Aquatic-GS[25] 则针对水下场景的特殊几何分布进行了适应性设计。上述工作共同表明，水下 3DGS 方向已成为当前研究热点[26]。

1.2.3 动态场景重建

真实水下场景普遍包含动态元素，如游动的鱼类、随水流摆动的海草及漂浮的颗粒物等，因此动态场景重建方法对水下应用具有重要意义。

在基于 NeRF 的动态场景重建方面，Nerfies[27] 引入弹性正则化约束，将变形场建模为近刚性变换，适用于包含轻微非刚性运动的视频序列；D-NeRF[28] 通过隐式变形场将动态场景分解为规范空间表示与时变形变，建立了动态 NeRF 的基本范式。

在基于 3DGS 的动态场景建模方面，Dynamic 3D Gaussians[29] 对每帧高斯体进行独立优化，通过时序一致性约束实现动态追踪。4DGaussians[30] 采用多分辨率哈希编码与轻量级 MLP 建模高斯体的时变形变，以四维时空坐标 (x, y, z, t) 为输入预测高斯属性的动态变化，在保持 3DGS 高效渲染优势的同时实现了对复杂动态场景的有效建模，是本文采用的基础动态场景框架。

1.2.4 深度监督与几何正则化

几何一致性是高质量三维重建的基础。在水下场景中，光学退化效应使得基于像素一致性的几何优化更为困难，引入外部深度先验作为监督信号是改善几何质量的有效途径。

UDR-GS[31] 是当前少数同时考虑水下环境与动态因素的工作之一，其采用深度引导初始化与基于 Canny 边缘检测的平滑正则化策略，在珊瑚礁场景上将

PSNR 从 31.14dB 提升至 32.43dB，验证了深度监督对水下 3DGS 几何一致性的有效提升作用。

Depth Anything[32] 及其升级版 Depth Anything V2[33] 提供了强大的单目深度估计能力，通过在大规模数据集上的预训练，可在无需额外设备的条件下从单张图像中估计出稠密、相对准确的深度图。将上述单目深度先验与 3DGS 框架结合，已被多项工作证明是提升几何重建质量的可行路径。

1.2.5 技术融合趋势与研究空白

综合以上分析，现有方法均在某一维度上取得了进展，但尚无工作能够在统一框架下同时解决水下场景的三个核心问题：

- SeaSplat 等工作成功实现了水下颜色物理建模，但仅限于静态场景，无法处理水下动态扰动；
- 4DGaussians 等动态场景方法提供了高效的时变高斯建模能力，但完全忽略了水下光学退化的物理机制；
- UDR-GS 引入了深度监督以改善几何一致性，但其水下颜色复原能力仍有明显局限。

这一研究空白表明，构建一个能够同时兼顾水下物理退化建模、动态场景表示与几何深度监督的统一方法，是当前水下场景新视角合成领域亟待解决的问题，也是本文的核心出发点。

第三节 主要研究内容与贡献

针对上述研究空白，本文提出了一种面向扰动水下环境的新视角合成方法，通过将水下物理成像模型、动态高斯场景表示与单目深度监督有机融合，实现对复杂水下场景的高质量三维重建与新视角渲染。本文的主要研究内容与创新贡献如下：

（**1**）**水下物理模型向动态高斯框架的迁移**。本文以 4DGaussians 为基础动态场景表示框架，将 SeaSplat 中验证有效的水下物理成像模型迁移至其渲染流程之中。具体而言，本文设计了与动态高斯渲染流程相兼容的 BackscatterNet 与 AttenuateNet 网络模块，分别对水下后向散射项与波长相关的衰减系数进行预测，并构建了融合水下物理约束的复合损失函数，使模型能够在优化动态场景结构的同时完成水下颜色退化的显式建模与补偿。

（**2**）**基于 Depth Anything V2 的单目深度监督机制**。本文引入 Depth Anything V2 预训练模型对输入图像序列进行单目深度估计，并将所得深度图以软约束的

形式集成至 3DGS 训练过程，构建深度一致性损失项对高斯体的空间分布进行约束。该机制有效抑制了水下场景中因光学退化而诱发的高斯体悬浮伪影，提升了重建场景的几何一致性。

（**3**）**分阶段训练策略设计与实验验证**。为协调水下物理建模、动态形变学习与深度监督三个优化目标的相互作用，本文设计了分阶段训练策略：在初始阶段优先建立稳健的几何结构，在后续阶段逐步引入物理约束与动态形变，降低各模块之间的梯度干扰。本文在多个水下图像数据集上进行了系统性实验，通过 PSNR、SSIM[34] 和 LPIPS[35] 等指标对所提方法进行定量评估，并与 SeaSplat、4DGaussians 等基线方法进行对比分析，验证了各模块设计的有效性。

第四节　论文组织结构

本文共分为五章，各章节内容安排如下：

第一章：绪论。介绍研究背景与意义，分析水下场景三维重建面临的核心挑战，综述国内外相关研究现状，阐述本文的研究内容与主要贡献，并给出论文整体组织结构。

第二章：相关技术基础。系统介绍本文所涉及的核心技术背景，包括三维高斯散射的基本原理与渲染流程、水下图像物理成像模型的数学描述、基于哈希编码的动态高斯形变建模方法，以及单目深度估计网络的相关理论，为后续方法设计提供理论支撑。

第三章：系统设计与实现。详细阐述本文提出的面向扰动水下环境的新视角合成方法，包括整体框架设计、水下物理模型的迁移与集成方案、单目深度监督机制的具体实现，以及分阶段训练策略的设计思路与实现细节。

第四章：实验与分析。介绍实验数据集、评价指标与实验设置，与现有基线方法进行定量与定性对比，并通过消融实验对各关键模块的贡献进行深入分析，验证所提方法的有效性。

第五章：总结与展望。对全文工作进行总结，指出现有方法的局限性，并对未来研究方向进行展望。

第二章 相关技术基础

本章介绍本文研究所涉及的核心技术基础，包括三维高斯散射（3D Gaussian Splatting）的基本原理、水下图像成像的物理模型、面向水下场景的 SeaSplat 建模方法、以及 4DGaussians 动态重建框架和单目深度估计技术。这些技术共同构成本文方法的理论基石，理解其原理对于把握后续章节中方法设计的动机与思路至关重要。

第一节 3D Gaussian Splatting 基础

3D Gaussian Splatting（3DGS）[11] 是一种基于显式点云表示的实时神经辐射场渲染方法。与 NeRF[5] 等隐式方法依赖神经网络对空间点进行隐式编码不同，3DGS 直接将场景表示为一组三维高斯基元的集合，并通过可微光栅化实现高效的图像合成。该方法在保持高质量渲染效果的同时，可达到实时渲染帧率，在新视角合成领域取得了显著突破。

2.1.1 场景表示

在 3DGS 框架中，三维场景由 N 个三维高斯基元 $\{\mathcal{G}_i\}_{i=1}^{N}$ 共同描述。每个高斯基元携带以下可学习属性：

- **位置**：$\mu_i \in \mathbb{R}^3$，表示高斯基元的空间中心；
- **协方差矩阵**：$\Sigma_i \in \mathbb{R}^{3\times 3}$，描述高斯基元的形状与朝向；
- **球谐系数**：$\mathbf{c}_i$，用于表示视角相关的颜色；
- **不透明度**：$\alpha_i \in [0,1]$，控制基元的透明程度。

每个高斯基元在三维空间中的密度分布由以下公式定义：

$$\mathcal{G}(\mathbf{x}) = \exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^\top \Sigma^{-1}(\mathbf{x}-\mu)\right) \tag{2.1}$$

其中 $\mathbf{x} \in \mathbb{R}^3$ 为空间中的任意查询点，μ 为高斯中心，Σ 为协方差矩阵。

为保证协方差矩阵的半正定性，同时使其可通过梯度下降进行优化，3DGS 将 Σ 分解为缩放矩阵与旋转矩阵的组合形式：

$$\Sigma = \mathbf{R}\mathbf{S}\mathbf{S}^\top \mathbf{R}^\top \tag{2.2}$$

其中 $\mathbf{S} = \mathrm{diag}(s_x, s_y, s_z)$ 为对角缩放矩阵，$s_x, s_y, s_z > 0$ 为三个轴方向的缩放因

子；$\mathbf{R}$ 为由单位四元数 $\mathbf{q}$ 参数化的旋转矩阵。通过分别优化缩放向量 $\mathbf{s} \in \mathbb{R}^3$ 和旋转四元数 $\mathbf{q} \in \mathbb{R}^4$，可以确保协方差矩阵在整个优化过程中始终保持物理上的合法性。视角相关颜色通过球谐函数（Spherical Harmonics）展开表示，在初始阶段使用低阶（0 阶）球谐系数，随训练进行逐步提升阶数以捕捉更精细的视角变化效果。

2.1.2 可微光栅化渲染

给定相机的内参矩阵 $\mathbf{K}$ 与外参矩阵 $[\mathbf{R}_c|\mathbf{t}_c]$，三维高斯基元首先被投影至二维图像平面。投影后，三维协方差矩阵 Σ 变换为二维协方差矩阵 $\Sigma' \in \mathbb{R}^{2\times 2}$：

$$\Sigma' = \mathbf{J}\mathbf{W}\Sigma\mathbf{W}^\top\mathbf{J}^\top \tag{2.3}$$

其中 $\mathbf{W}$ 为视图变换矩阵，$\mathbf{J}$ 为射影变换的仿射近似雅可比矩阵。

完成投影后，图像中某像素 $\mathbf{p}$ 的颜色通过深度排序后的 α 混合（Alpha Compositing）公式计算：

$$\mathbf{C}(\mathbf{p}) = \sum_{i=1}^{N} \mathbf{c}_i \hat{\alpha}_i \prod_{j=1}^{i-1}(1-\hat{\alpha}_j) \tag{2.4}$$

其中 $\mathbf{c}_i$ 为第 i 个高斯基元在当前视角下由球谐函数计算得到的颜色，$\hat{\alpha}_i$ 为结合二维高斯密度与不透明度 α_i 后的有效透明度值：

$$\hat{\alpha}_i = \alpha_i \cdot \exp\left(-\frac{1}{2}(\mathbf{p}-\mu_i')^\top \Sigma_i'^{-1}(\mathbf{p}-\mu_i')\right) \tag{2.5}$$

类似地，像素的深度值通过相同的混合权重对各高斯基元的投影深度 z_i 加权得到：

$$D(\mathbf{p}) = \sum_{i=1}^{N} z_i \hat{\alpha}_i \prod_{j=1}^{i-1}(1-\hat{\alpha}_j) \tag{2.6}$$

在实现层面，3DGS 采用基于图块（Tile-based）的并行光栅化策略：将图像划分为若干 16×16 像素的图块，对每个图块内的高斯基元按深度排序后并行执行 α 混合，从而实现在 GPU 上的高效实时渲染。

2.1.3 自适应密度控制

3DGS 在训练过程中对高斯基元的数量与分布进行动态调整，以适应不同复杂度的场景结构，这一机制称为自适应密度控制（Adaptive Density Control）。

致密化（Densification）：当某区域的几何结构未得到充分重建时，系统通过检测各高斯基元的位置梯度均值 $\bar{\nabla}_\mu$ 来识别欠重建区域。当梯度均值超过预设阈值 τ_{pos} 时，触发以下两种操作：

- **克隆（Clone）**：对尺寸较小的高斯基元，在其梯度方向复制一个新基元，用于填充欠采样区域；
- **分裂（Split）**：对尺寸过大的高斯基元（最大缩放因子超过阈值 τ_{scale}），将其拆分为两个较小的高斯基元，以更精细地建模复杂几何细节。

剪枝（Pruning）：每隔固定迭代步数，将不透明度 α_i 低于阈值 τ_α 的高斯基元从场景中移除，以消除无效基元并防止基元数量无限增长。此外，定期将所有基元的不透明度重置为较小值，并通过后续训练决定其是否保留，从而实现自动剪枝。

通过上述自适应密度控制策略，3DGS 能够在保持场景表示紧凑性的同时，自动在复杂区域增加表示容量，在简单区域降低冗余度，显著提升了场景重建的质量与效率。

第二节 水下图像成像模型

水下环境中的光学成像与空气中存在本质差异。水分子及其中悬浮的微粒对光线的吸收与散射会导致图像出现颜色偏移、对比度下降和细节模糊等退化现象，理解这些物理过程是构建水下场景重建方法的基础。

2.2.1 光在水中的传播特性

光在水介质中传播时遵循 Beer-Lambert 定律[3]，即光强随传播距离呈指数衰减：

$$I(d,\lambda) = I_0(\lambda) \cdot \exp(-\alpha(\lambda) \cdot d) \tag{2.7}$$

其中 $I(d,\lambda)$ 为光线经距离 d 传播后在波长 λ 处的强度，$I_0(\lambda)$ 为初始光强，$\alpha(\lambda)$ 为波长相关的衰减系数。由于水对红光的吸收系数远大于蓝绿光，水下图像通常呈现明显的蓝绿色偏色现象。

除吸收效应外，水体中的散射效应同样不可忽视，主要分为两类[12, 13]：

- **前向散射（Forward Scattering）**：光线在传播方向发生小角度偏折，导致场景中物体边缘模糊，降低图像清晰度；
- **后向散射（Backscattering）**：水体中的微粒将环境光反射回相机，在图像上形成随深度增大而增厚的雾状遮蔽层（Water Column Veil），严重降低图像对比度与可见距离。

2.2.2 修正水下图像形成模型

基于上述物理分析，Akkaynak 与 Treibitz 提出了修正水下图像形成模型（Revised Underwater Image Formation Model）[15, 16]，该模型在经典 Jaffe-McGlamery 模型基础上，将直接透射衰减与后向散射衰减分别参数化，更加精确地描述了水下光学成像过程。对于颜色通道 $c \in \{r, g, b\}$，图像像素值 I_c 满足：

$$I_c = J_c \cdot \exp\left(-\beta_c^D \cdot Z\right) + B_c^\infty \cdot \left(1 - \exp\left(-\beta_c^B \cdot Z\right)\right) \tag{2.8}$$

其中各符号的物理含义如下：

- J_c：场景在无水介质干扰时的真实颜色（清晰场景图像）；
- Z：场景点到相机的距离（深度）；
- β_c^D：直接透射分量的波长相关衰减系数；
- β_c^B：后向散射分量的波长相关衰减系数；
- B_c^∞：无穷远处后向散射的饱和颜色值。

该模型揭示了水下图像退化的两个核心机制：第一项描述清晰场景颜色随深度指数衰减的过程，第二项描述随深度增大、后向散射逐渐主导成像的过程。当 $Z \to \infty$ 时，图像趋向于均匀的后向散射背景颜色 B_c^∞。该模型是 SeaSplat[18] 方法的核心物理依据。

2.2.3 暗通道先验

暗通道先验（Dark Channel Prior，DCP）由 He 等人[14] 提出，是图像去雾领域的经典先验假设。其核心观察为：在无雾的自然图像中，绝大多数局部区块内至少存在一个颜色通道，其像素值接近于零。形式化定义为：

对于无雾图像 J，其暗通道 J^{dark} 定义为：

$$J^{\text{dark}}(\mathbf{x}) = \min_{c \in \{r,g,b\}} \min_{\mathbf{y} \in \Omega(\mathbf{x})} J^c(\mathbf{y}) \tag{2.9}$$

其中 $\Omega(\mathbf{x})$ 为以像素 $\mathbf{x}$ 为中心的局部邻域窗口，$J^c(\mathbf{y})$ 为像素 $\mathbf{y}$ 在颜色通道 c

上的强度值。对于无雾清晰图像，统计规律表明 $J^{\text{dark}}(\mathbf{x}) \approx 0$。

在水下场景复原中，暗通道先验被用作正则化约束：要求网络恢复出的清晰图像 J 的暗通道尽量趋近于零，从而抑制后向散射的污染效应，约束网络输出物理上合理的清晰场景颜色。这一先验虽然并非对所有水下场景严格成立，但作为软约束可以有效引导优化方向。

第三节 SeaSplat 水下建模方法

SeaSplat[18] 是在 3DGS 框架基础上专门针对水下场景设计的建模方法，其核心思想是将修正水下图像形成模型嵌入 3DGS 的可微渲染流程，通过轻量级的神经网络模块估计水体光学参数，从而在重建场景三维结构的同时实现水下图像的物理解耦。

2.3.1 BackscatterNet 网络

后向散射估计网络（BackscatterNet）负责从深度图中估计后向散射颜色图 **B**。该网络采用轻量级的深度图卷积结构，以渲染得到的深度图 **Z** 作为输入，输出每通道的后向散射强度：

$$B_c(z) = \sigma(B_c^{\infty}) \cdot (1 - \exp(-\beta_c \cdot z)) \tag{2.10}$$

其中 $\sigma(\cdot)$ 为 Sigmoid 激活函数，B_c^{∞} 为可学习的无穷远处后向散射颜色参数，β_c 为可学习的后向散射衰减系数。Sigmoid 函数将 B_c^{∞} 约束在 $(0,1)$ 范围内，保证颜色值的物理合理性。

BackscatterNet 的网络参数量约为 1K，计算开销可忽略不计，在引入水下物理建模能力的同时不对整体渲染速度产生明显影响。

2.3.2 AttenuateNet 网络

直接透射衰减估计网络（AttenuateNet）负责计算场景颜色随深度的衰减映射。SeaSplat 采用 AttenuateNetV3 变体，其结构最为简洁，训练稳定性最优：

$$A_c(z) = \exp(-\beta_c^{\text{conv}} \cdot z) \tag{2.11}$$

其中 β_c^{conv} 为每通道单独学习的衰减系数，无需额外的卷积结构，直接将深度 z 通过指数变换映射为衰减系数图。最终渲染颜色与水下物理模型的耦合形式为：

$$\hat{I}_c = \mathbf{C}_c \cdot A_c(\mathbf{Z}) + B_c(\mathbf{Z}) \tag{2.12}$$

其中 $\mathbf{C}_c$ 为 3DGS 光栅化输出的清晰场景颜色图，$\mathbf{Z}$ 为深度图，A_c 与 B_c 分别由 AttenuateNet 和 BackscatterNet 估计。

2.3.3 水下损失函数

SeaSplat 在标准 3DGS 的光度损失基础上，增加了一系列面向水下物理特性的正则化损失项，以提升水下参数估计的准确性与稳定性。

暗通道先验损失（$\mathcal{L}_{\text{dark}}$）：最小化恢复出的清晰场景图像 $\hat{J}$ 的暗通道均值，促使清晰场景符合自然图像的统计规律：

$$\mathcal{L}_{\text{dark}} = \frac{1}{|\mathcal{P}|} \sum_{\mathbf{p} \in \mathcal{P}} J^{\text{dark}}(\mathbf{p}) \tag{2.13}$$

灰度世界损失（$\mathcal{L}_{\text{gray}}$）：假设清晰场景在全图上各颜色通道均值应趋于中性灰（0.5），以纠正颜色偏差：

$$\mathcal{L}_{\text{gray}} = \sum_{c \in \{r,g,b\}} \left(\frac{1}{|\mathcal{P}|} \sum_{\mathbf{p}} \hat{J}_c(\mathbf{p}) - 0.5 \right)^2 \tag{2.14}$$

饱和度损失（$\mathcal{L}_{\text{sat}}$）：惩罚清晰场景图像中超出 $[0,1]$ 范围的像素值，防止颜色过曝或欠曝：

$$\mathcal{L}_{\text{sat}} = \frac{1}{|\mathcal{P}|} \sum_{\mathbf{p}} \max\left(0, \hat{J}(\mathbf{p}) - 1\right) + \max\left(0, -\hat{J}(\mathbf{p})\right) \tag{2.15}$$

背景散射损失（$\mathcal{L}_{\text{bg}}$）：抑制水柱中漂浮的高斯基元，防止模型将后向散射误建模为场景几何：

$$\mathcal{L}_{\text{bg}} = \frac{1}{N} \sum_{i=1}^{N} \alpha_i \cdot \mathbf{1}[z_i > z_{\text{thresh}}] \tag{2.16}$$

深度平滑损失（$\mathcal{L}_{\text{smooth}}$）：鼓励渲染深度图在相邻像素之间平滑变化，减少深度估计中的噪声：

$$\mathcal{L}_{\text{smooth}} = \sum_{\mathbf{p}} |\nabla_x D(\mathbf{p})| + \left|\nabla_y D(\mathbf{p})\right| \tag{2.17}$$

总损失函数为各项加权之和：

$$\mathcal{L} = \mathcal{L}_{\text{photo}} + \lambda_1 \mathcal{L}_{\text{dark}} + \lambda_2 \mathcal{L}_{\text{gray}} + \lambda_3 \mathcal{L}_{\text{sat}} + \lambda_4 \mathcal{L}_{\text{bg}} + \lambda_5 \mathcal{L}_{\text{smooth}} \tag{2.18}$$

第四节 4DGaussians 动态重建方法

4DGaussians[30] 是将 3DGS 扩展至动态场景重建的代表性方法之一，通过引入时间维度和变形网络，实现了对非刚性运动场景的高效重建与渲染。该方法在动态 3D 高斯散射（Dynamic 3DGS）[29] 等工作基础上，利用 HexPlane 时空特征平面编码高效捕捉场景的时空相关性。

2.4.1 时间维度扩展

在 4DGaussians 框架中，场景由一组规范空间（Canonical Space）中的高斯基元描述，每个基元通过变形网络（Deformation Network）得到时刻 t 下的形变属性偏移量。给定第 i 个高斯基元在规范空间中的位置 μ_i，变形网络 $\mathcal{F}$ 接收四维时空坐标 (x_i, y_i, z_i, t) 作为输入，预测各属性的偏移量：

$$(\Delta\mu_i, \Delta\mathbf{s}_i, \Delta\mathbf{q}_i, \Delta\alpha_i) = \mathcal{F}(x_i, y_i, z_i, t) \tag{2.19}$$

时刻 t 下各基元的最终属性通过规范属性与偏移量叠加得到：

$$\mu_i' = \mu_i + \Delta\mu_i, \quad \mathbf{s}_i' = \mathbf{s}_i + \Delta\mathbf{s}_i, \quad \mathbf{q}_i' = \mathbf{q}_i + \Delta\mathbf{q}_i, \quad \alpha_i' = \alpha_i + \Delta\alpha_i \tag{2.20}$$

随后，时刻 t 的渲染图像由变形后的高斯集合通过标准 3DGS 光栅化流程得到。这种规范空间加变形网络的设计将场景的静态结构信息与动态运动信息解耦，有利于两者的分别优化。

2.4.2 HexPlane 多分辨率时空网格

变形网络的核心模块为 HexPlane 时空特征平面[36]。HexPlane 将四维时空体（x, y, z, t）分解为 6 个二维特征平面，分别对应三维空间的 3 个空间平面（xy、xz、yz）和 3 个时空平面（xt、yt、zt）：

$$\mathbf{f}(\mathbf{x}, t) = \bigcup_{(u,v) \in \{xy, xz, yz, xt, yt, zt\}} \Phi_{uv}(u(\mathbf{x}, t), v(\mathbf{x}, t)) \tag{2.21}$$

其中 Φ_{uv} 表示对应二维特征平面的双线性插值查询，$u(\cdot)$ 和 $v(\cdot)$ 为从四维坐

标中提取对应分量的投影操作。6 个平面查询得到的特征向量拼接后输入轻量级 MLP，得到最终的形变预测。

为捕捉不同尺度下的时空相关性，HexPlane 采用多分辨率特征方案：在 1×、2×、4× 三种分辨率下分别维护一组特征平面，对应分辨率的查询结果拼接后共同表达多尺度的时空信息。这种分解策略将四维时空体的存储与计算复杂度由 $O(N^4)$ 降低至 $O(N^2)$，大幅提升了方法的可扩展性。

2.4.3 变形网络架构

变形网络的完整架构包含三个模块：位置编码模块、HexPlane 特征提取模块和 MLP 预测头。

输入的四维时空坐标 (x, y, z, t) 首先通过正弦位置编码（Sinusoidal Positional Encoding）进行高频特征扩展，增强网络对细节运动的表达能力。随后，编码后的坐标通过 HexPlane 的 6 个平面查询提取时空特征，并将 6 组特征拼接后送入多层感知机。MLP 输出层设置独立的预测头分别输出位置偏移 $\Delta\mu$、缩放偏移 $\Delta\mathbf{s}$、旋转偏移 $\Delta\mathbf{q}$ 和不透明度偏移 $\Delta\alpha$。为支持视角相关的动态颜色变化，可选地引入球谐系数偏移预测头 $\Delta\mathbf{c}$。

在场景中同时存在静态背景与动态前景时，4DGaussians 通过动/静分离机制为两类高斯基元分别处理：静态基元不经过变形网络，直接在规范空间中渲染；动态基元的属性则经变形网络预测后再进行渲染，从而避免对静态场景部分不必要的形变扰动。

2.4.4 两阶段训练策略

4DGaussians 采用粗细两阶段的训练策略，以稳定优化过程并提升最终重建质量。

粗阶段（Coarse Stage）：在此阶段关闭变形网络，仅优化规范空间中的高斯基元属性（位置、形状、颜色、不透明度），同时进行自适应密度控制。此阶段的目标是在规范空间中建立稳定的场景几何骨架，为后续动态建模提供良好的初始化。

细阶段（Fine Stage）：在粗阶段的高斯初始化基础上，联合优化高斯属性和变形网络，使模型逐步学习场景中的动态变化。细阶段的损失函数为：

$$\mathcal{L} = (1-\lambda)\mathcal{L}_1 + \lambda\mathcal{L}_{\text{SSIM}} + \lambda_{\text{TV}}\mathcal{L}_{\text{TV}} + \lambda_t\mathcal{L}_t \tag{2.22}$$

其中 $\mathcal{L}_1$ 为像素级 L1 损失，$\mathcal{L}_{\text{SSIM}}$ 为结构相似性损失[34]，$\mathcal{L}_{\text{TV}}$ 为 HexPlane 特征平面的全变分（Total Variation）正则化损失，用于约束特征平面的空间平滑性，$\mathcal{L}_t$ 为时间平滑性损失，惩罚相邻时刻之间的形变突变，有效抑制时间维度上的抖动现象。

第五节　单目深度估计

准确的深度信息对于水下场景重建和水体参数估计具有重要意义，然而水下环境通常缺乏主动深度传感器。单目深度估计（Monocular Depth Estimation）提供了一种仅依赖 RGB 图像推断场景深度的方案。

Depth Anything V2[33] 是目前性能最优的单目深度估计模型之一，通过在大规模合成数据与真实数据混合训练集上进行预训练，获得了强大的跨场景泛化能力，在自然场景、室内场景乃至水下场景均展现出良好的深度估计性能。

该模型的输出为相对逆深度图（Relative Inverse Depth Map）$\hat{D}_{\text{inv}}$，与真实深度 Z 的关系为：

$$\hat{D}_{\text{inv}} \propto \frac{1}{Z} \tag{2.23}$$

采用逆深度表示的优势在于其数值分布更为均匀：近处物体的逆深度值较大且变化范围宽，远处物体逆深度值较小且趋于集中，这一特性与水下场景中远处物体因水体散射而自然模糊的视觉规律相契合，有助于在近处提供更精细的深度监督信号。

在本文的方法中，Depth Anything V2 的输出被用作弱监督信号（Weak Supervision）：在训练过程中，通过仿射不变深度损失将 3DGS 渲染的深度图与预测逆深度图进行尺度-偏移对齐后施加监督，引导场景几何向更合理的深度分布收敛，同时避免对单目深度估计绝对精度的过度依赖。这种弱监督策略在无主动深度传感器的水下场景中尤为实用，可以有效缓解仅依赖光度损失进行几何优化时容易出现的尺度模糊与深度坍塌等问题。

第三章 系统设计与实现

本章详细阐述面向扰动水下环境的新视角合成系统的完整设计与实现方案。系统以 4D Gaussian Splatting[30] 为动态场景表示骨架，将 SeaSplat[18] 的水下物理成像模型嵌入其渲染流程，并引入 Depth Anything V2[33] 提供单目深度先验监督，形成三位一体的联合优化框架。

第一节 总体框架设计

3.1.1 设计思路

本系统的核心目标是在统一框架下同时解决三个相互耦合的难题：（1）水下光学退化对颜色与对比度的干扰；（2）水流、生物游动等因素引起的动态场景变化；（3）水下场景几何重建的深度歧义性。

针对上述挑战，系统采用” 物理解耦—动态建模—深度监督” 三层递进的设计思路。

物理解耦层。水下成像过程遵循修正的水下图像成像模型[15]，该模型将观测图像分解为干净场景辐射度与水体介质效应的叠加。系统引入可学习的衰减网络（AttenuateNet）和背散射网络（BackscatterNetV2），在渲染阶段显式建模光的衰减与后向散射，使高斯点云只需学习物体本身的真实颜色，而非被水体介质污染后的表观颜色。

动态建模层。4DGS 通过时间条件化的变形网络（Deformation Network）对高斯点云的位置、旋转与尺度进行时序调制，结合 HexPlane 多分辨率特征平面高效表达动态场景。本系统继承该机制以应对水下扰动引入的非刚性运动。

深度监督层。水下场景往往缺乏结构光或激光测距等主动深度传感器，多视角几何约束在水体散射干扰下也易出现退化。本系统利用 Depth Anything V2[33] 预生成单目逆深度图，对渲染深度施加软约束，引导几何收敛至合理形状。

整体处理流程如图 3-1 所示：采集多视角水下图像序列后，首先利用 COLMAP 进行运动恢复结构（SfM）获得稀疏点云与相机位姿；随后以稀疏点云初始化 4D 高斯点集，进入两阶段训练（粗训练与精细训练）；最终系统可在任意时刻以任意视角渲染新视图。

3.1.2 系统架构

系统渲染管线由以下模块串联构成，如图 3-2 所示。

（**1**）**4D 高斯点集**。场景由 N 个三维高斯椭球体参数化，每个高斯体携带位置 $\mu \in \mathbb{R}^3$、协方差 $\Sigma \in \mathbb{R}^{3\times 3}$、不透明度 $\alpha \in (0,1)$、球谐系数 $\mathbf{f}$ 以及时间戳 t[11, 30]。

（**2**）**变形网络**。对于给定时刻 t，HexPlane 特征平面与多层感知机（MLP）联合输出每个高斯体的位置增量 $\Delta\mu$、旋转增量 $\Delta\mathbf{r}$ 和尺度增量 $\Delta\mathbf{s}$，从而将静态高斯点云变形为当前帧的动态状态。

（**3**）**高斯光栅化**。经变形后的高斯点云通过可微分的基于分块排序的光栅化算法投影至图像平面，输出干净场景颜色图 $\mathbf{J} \in \mathbb{R}^{H\times W\times 3}$ 及深度图 $\mathbf{Z} \in \mathbb{R}^{H\times W}$。$\mathbf{J}$ 代表在无水体介质干扰时的真实辐射度。

（**4**）**水下成像模型**。将 $\mathbf{J}$ 和 $\mathbf{Z}$ 输入水下物理模型，生成模拟观测图像 $\mathbf{I}$：

$$I_c = J_c \cdot \exp\left(-\beta_c^D \cdot Z\right) + B_c^\infty \cdot \left(1 - \exp\left(-\beta_c^B \cdot Z\right)\right) \tag{3.1}$$

其中 $c \in \{R, G, B\}$ 为颜色通道，β_c^D 为衰减系数，B_c^∞ 为无穷远处背散射强度，β_c^B 为背散射系数。上述参数均由网络动态预测。

（**5**）**联合优化**。将合成图像 $\mathbf{I}$ 与真实观测图像 $\mathbf{I}^{\mathrm{gt}}$ 进行对比，梯度同时回传至高斯参数和水下网络参数，实现端到端联合优化。梯度沿路径 $\mathbf{I} \to \mathbf{J} \to$ 高斯点集和 $\mathbf{I} \to \{A(Z), B(Z)\} \to$ 水下网络 两条并行通路传播。

第二节 SeaSplat 水下模块迁移

3.2.1 代码框架差异分析

SeaSplat[18] 基于原始 3DGS 静态框架实现，而 4DGS[30] 在其基础上引入了变形网络、HexPlane 多分辨率特征表示及多分辨率哈希编码等核心组件，二者在接口设计与数据流结构上存在显著差异，迁移工作面临以下三个方面的挑战。

渲染函数接口差异。3DGS 的渲染函数以静态高斯参数为输入，而 4DGS 在调用光栅化之前需先经过变形网络的时序处理，渲染函数签名扩展了时间戳和变形结果等额外参数。迁移时需将水下模块的介入点后移至光栅化之后，以确保输入给水下模型的颜色图 $\mathbf{J}$ 是经过完整时序处理的干净渲染结果。

优化器管理差异。4DGS 引入了 HexPlane 特征平面参数和变形 MLP 参数两组新的可学习参数，其学习率调度策略与 3DGS 原有的高斯属性参数不同。水下模型新增的网络参数需作为独立参数组注册至优化器，并配置专属的学习率

与衰减策略，以避免与已有参数组的调度逻辑相互干扰。

动态与静态表示的协同。SeaSplat 假设场景静止，其推断的深度图在不同帧之间保持一致。引入 4DGS 后，每帧的高斯形态因变形网络而不同，导致深度图在时序上动态变化。水下物理模型必须以当前帧的实时渲染深度作为输入，而非预存的静态深度缓存。

综合考虑上述差异，迁移策略确定为：在保持 4DGS 变形流程完全不变的前提下，在光栅化输出之后、损失计算之前插入水下成像模块，以最小侵入的方式实现功能集成。

3.2.2 核心模块迁移

BackscatterNetV2。背散射网络负责根据深度图预测逐像素的背散射贡献。网络结构为两层轻量卷积（Conv2D），以归一化深度图为输入，输出背散射颜色图 $\mathbf{B}(Z)$：

$$B_c(Z) = \mathrm{sigmoid}(B_c^{\infty}) \cdot \left(1 - \exp(-\beta_c^B \cdot Z)\right) \tag{3.2}$$

网络参数量约 1K，计算开销极小。该模块已迁移至 deepseecolor/models.py，作为独立的 nn.Module 注册，以便与主优化器统一管理。

AttenuateNetV3。衰减网络有三种变体（V1、V2、V3），经消融实验对比后选用 V3 版本，因其训练过程最为稳定。V3 采用单参数逐通道设计，对每个颜色通道学习一个标量衰减系数 β_c^D，衰减图计算如下：

$$A_c(Z) = \exp\left(-\beta_c^D \cdot Z\right) \tag{3.3}$$

参数初始化以较小正值为起点，使系统初始阶段接近无衰减状态，便于粗训练阶段高斯几何的稳定收敛。

损失函数迁移。水下专用损失函数迁移至 deepseecolor/losses.py，包含以下四个组件：

- **暗通道先验损失（DarkChannelPriorLoss）**：基于 He 等人[14] 提出的暗通道先验，约束干净场景图像 $\mathbf{J}$ 在局部窗口内至少有一个通道接近零，防止网络将水体散射残留嵌入干净图像；
- **灰世界先验损失（GrayWorldPriorLoss）**：约束干净图像每个颜色通道的均值趋向 0.5，避免颜色通道间出现偏置性亮度不平衡；
- **RGB 饱和度损失（RgbSaturationLoss）**：惩罚 $\mathbf{J}$ 中超出 $[0,1]$ 范围的像素

值，维护物理合理性；

- **Alpha 背景损失（AlphaBackgroundLoss）**：抑制相机前方水柱区域的高斯体不透明度，防止系统学习到虚假的水体填充体素，迁移时针对批尺寸 $b = 1$ 对掩码张量维度进行了专项修复。

3.2.3 渲染流程修改

图 3-3 展示了完整的修改后渲染流程。在原有 4DGS 光栅化输出干净颜色 $\mathbf{J}$ 和深度 $\mathbf{Z}$ 之后，额外执行以下步骤：

步骤一：深度归一化。将原始渲染深度归一化至 $[0, 1]$ 区间：

$$\hat{Z} = \frac{Z - Z_{\min}}{Z_{\max} - Z_{\min} + \varepsilon} \tag{3.4}$$

归一化参数可按帧动态计算（帧级最大最小值）或使用全局统计量。在精细训练阶段采用帧级归一化以适应场景深度分布的动态变化。

步骤二：水下网络前向传播。将归一化深度 $\hat{Z}$ 分别送入 AttenuateNetV3 和 BackscatterNetV2，得到衰减图 $\mathbf{A}(\hat{Z})$ 和背散射图 $\mathbf{B}(\hat{Z})$。

步骤三：水下成像合成。按照式(3.1)合成模拟水下图像 $\mathbf{I}$：

$$\mathbf{I} = \mathbf{J} \odot \mathbf{A}(\hat{Z}) + \mathbf{B}(\hat{Z}) \tag{3.5}$$

其中 $\odot$ 表示逐元素乘法。

上述过程在 gaussian_renderer/__init__.py 中实现，水下工具函数封装于 utils/underwater_utils.py。整个合成路径完全可微，梯度可同时流向高斯点集参数和水下网络参数，满足端到端优化的需求。

第三节 单目深度监督实现

3.3.1 深度图生成流程

为缓解水下场景几何重建的深度歧义性，系统引入 Depth Anything V2[33] 作为单目深度先验来源。Depth Anything V2 是目前性能领先的单目深度估计模型，在多种室内外场景上展现出强泛化能力，其 Large 变体的单图推理时间约 100 毫秒，满足离线预处理的实用需求。

深度图生成通过脚本 scripts/generate_mono_depth_da2.py 批量完成，处理流程如下：

（1）遍历数据集训练图像目录，对每张图像运行 Depth Anything V2 的前向推理，得到逆深度图（inverse depth map）；

（2）将逆深度图归一化至 $[0,255]$ 区间并保存为 PNG 格式灰度图像，文件名与对应源图像保持一致；

（3）输出文件统一存储于数据集根目录下的 depth/子目录，系统在训练时根据图像文件名自动匹配对应的深度先验图。

选用逆深度而非线性深度的原因有以下两点：首先，水下远距离目标因散射效应造成视觉模糊，线性深度分布下远处区域的深度估计方差较大，逆深度变换可使近处高精度区域和远处区域在数值域中分布更为均匀；其次，逆深度与视差（disparity）等价，在立体匹配和单目深度估计领域具有良好的物理解释性。

3.3.2 监督机制

渲染深度获取。在高斯光栅化过程中，深度图 $\mathbf{Z}$ 通过复用颜色渲染的混合权重 w_i 对各高斯体中心深度进行加权累积得到：

$$Z(\mathbf{p}) = \sum_i w_i(\mathbf{p}) \cdot z_i \tag{3.6}$$

其中 $\mathbf{p}$ 为像素坐标，z_i 为第 i 个高斯体在相机坐标系下的深度值，$w_i(\mathbf{p})$ 与颜色渲染的混合权重共享，避免引入额外计算。

尺度不确定性处理。单目深度估计模型输出的深度图与真实度量深度之间存在未知的尺度与偏移不确定性。为消除该歧义，系统在计算损失前对渲染逆深度 d_{render} 和单目逆深度 d_{mono} 均进行基于均值和标准差的归一化处理：

$$\tilde{d} = \frac{d - \mu_d}{\sigma_d + \varepsilon} \tag{3.7}$$

此归一化操作使损失对绝对尺度不敏感，仅约束深度图的相对结构（即深度梯度与相对远近关系）与单目先验保持一致。

损失函数。单目深度监督损失定义为归一化逆深度图之间的加权 L1 距离：

$$\mathcal{L}_{\text{mono}} = \left\| \tilde{d}_{\text{render}} - \tilde{d}_{\text{mono}} \right\|_1 \odot \alpha \tag{3.8}$$

其中 $\alpha \in [0,1]^{H \times W}$ 为高斯渲染的累积透明度图（alpha mask），对高斯覆盖良好的区域给予更高监督权重，对空白背景区域减少干扰。

配置参数。系统通过配置项 mono_depth_dir="depth" 指定单目深度先验目录，mono_depth_inv=False 表明预存文件已为逆深度格式（无需额外取反），use_mono_depth_supervision=True 开启监督。深度监督损失权重 λ_{mono} 设定为 0.1，并配合热启动调度策略在训练初期逐步引入。

第四节 分阶段训练策略

分阶段训练策略是本系统应对多组件联合优化不稳定性的核心创新。当水下网络、变形网络与高斯点集同时从零开始优化时，三者之间存在严重的梯度干扰：水下网络若过早引入，会将颜色偏差错误地归因于几何结构，导致高斯几何收敛至错误形态。本系统设计了五个连续的训练阶段，总训练迭代次数为 20000 步。

3.4.1 粗训练阶段

迭代范围：0–3000 步。

该阶段为标准 4DGS 优化流程，水下物理模型未激活，系统等价于原始 4DGS 训练。损失函数为：

$$\mathcal{L}_{\text{coarse}} = \mathcal{L}_1(\mathbf{J}, \mathbf{I}^{\text{gt}}) + \lambda_{\text{ssim}} \mathcal{L}_{\text{SSIM}}(\mathbf{J}, \mathbf{I}^{\text{gt}}) \tag{3.9}$$

其中 $\lambda_{\text{ssim}} = 0.2$ 为 SSIM 损失权重。此阶段开启自适应密度控制（Adaptive Density Control），执行高斯体的分裂、克隆与修剪操作，建立场景的基础几何骨架。为避免视角相关颜色效应与后续水下模型产生干扰，球谐阶数固定为 0（仅使用 DC 项），使每个高斯体只学习与视角无关的漫反射颜色。

3.4.2 精细阶段初始化

时机：第 3001 步。

在粗训练结束时执行一次性初始化操作，创建 BackscatterNetV2 和 AttenuateNetV3 实例，并将其注册至优化器中的独立参数组，学习率初始值设为 5×10^{-4}。当配置项 bg_from_bs=True 时，利用粗训练阶段学习到的背景颜色初始化背散射网络的 B^{∞} 参数，使其从一个合理的先验值起步，加速精细阶段的收敛。

在初始化完成的第一个迭代步内，高斯体的位置、不透明度、缩放和旋转参数被临时冻结，仅开放颜色相关参数的更新，防止刚启用水下模型时不稳定

的梯度冲击几何结构。从第 3002 步起解冻全部参数。

3.4.3 背散射/衰减预热阶段

迭代范围：3001–4000 步（预热步数 bs_warmup_count=1000）。

该阶段设置 skip_gs_step=True，完全冻结高斯点集所有参数，仅更新 BackscatterNetV2 和 AttenuateNetV3 的参数。其目的在于：在高斯几何不受干扰的条件下，让水下物理模型快速捕捉水体介质的宏观光学特性（各通道衰减系数的量级与背散射基准强度），为后续联合优化提供稳定的水下模型初始化。此时损失仍为图像重建损失，但反向传播路径被截断，梯度不会到达高斯参数。

3.4.4 高斯颜色调整阶段

迭代范围：4001–6000 步（颜色调整步数 gs_color_adjust_count=2000）。

该阶段设置 skip_uwater_step=True，冻结水下网络参数，仅更新高斯点集的颜色属性（球谐系数和 DC 颜色）。其目的在于：经预热阶段水下网络基本确定了水体介质参数后，让高斯颜色在”去水”后的干净颜色空间中重新校准，使 **J** 逐步逼近真实物体的本征颜色，而非被水体污染的表观颜色。此阶段高斯的几何参数（位置、旋转、缩放）同样参与更新。

3.4.5 联合训练与突发更新阶段

迭代范围：6001–20000 步。

该阶段进入高斯点集与水下模型的全参数联合优化，并引入”突发更新”（burst update）机制以维持优化动态平衡：

- 每隔 update_bs_at_interval=100 步，连续进行 50 步的水下模型专项更新（skip_gs_step=True），称为一次”突发”；
- 突发之外的其余迭代步执行全参数联合更新。

该机制的物理动机是：随着场景几何的持续演变（高斯点云的位置和密度在联合优化中仍会变化），渲染深度图 **Z** 也随之改变，需要定期给水下网络提供专注的优化机会，使其跟上几何变化的节奏。

完整损失函数在该阶段激活全部组件：

$$\mathcal{L} = \mathcal{L}_1 + \lambda_{\text{ssim}}\mathcal{L}_{\text{SSIM}} + \lambda_{\text{ds}}\mathcal{L}_{\text{depth_smooth}} + \lambda_{\text{dcp}}\mathcal{L}_{\text{DCP}} + \lambda_{\text{gw}}\mathcal{L}_{\text{GW}} + \lambda_{\text{sat}}\mathcal{L}_{\text{SAT}} + \lambda_{\text{mono}}\mathcal{L}_{\text{mono}} \tag{3.10}$$

各损失项含义如下：$\mathcal{L}_1$ 为像素级 L1 重建损失；$\mathcal{L}_{\text{SSIM}}$ 为结构相似度损失[34]；$\mathcal{L}_{\text{depth_smooth}}$ 为深度平滑正则项，约束渲染深度图在空间上的平滑性；$\mathcal{L}_{\text{DCP}}$ 为暗通道先验损失[14]；$\mathcal{L}_{\text{GW}}$ 为灰世界先验损失；$\mathcal{L}_{\text{SAT}}$ 为 RGB 饱和度损失；$\mathcal{L}_{\text{mono}}$ 为单目深度监督损失（式(3.8)）。

为防止训练初期损失震荡，各辅助损失项采用线性热启动（warm-up）调度策略：

$$w(k) = w_{\text{base}} \cdot \min\left(1,\ \frac{k - k_{\text{start}}}{k_{\text{ramp}}}\right) \tag{3.11}$$

其中 k 为当前迭代步，k_{start} 为该损失项的激活步，k_{ramp} 为热启动步数（默认 500 步）。

第五节 稳定性优化

在实际工程实现过程中，多组件联合优化系统在训练中期暴露出若干 CUDA 运行时错误与数值不稳定问题。本节记录四项关键的稳定性修复措施。

3.5.1 GT 图像 CUDA 错误保护

问题描述。在部分训练帧上，执行 gt_image = viewpoint_cam.original_image.cuda() 时偶发非法内存访问（illegal memory access）错误，导致整个训练进程崩溃。

根因分析。水下视频数据集中存在少量损坏帧或元数据异常的图像文件，PyTorch 在将其移至 CUDA 设备时触发底层内存错误，错误信息通常延迟一个 CUDA 内核后才显现，难以直接定位。

解决方案。在 train.py 中以 try-except 包裹 GT 图像的 CUDA 移动操作，捕获 RuntimeError 异常后跳过当前帧并继续训练，同时记录跳过帧的索引以便事后审计，而非直接终止训练进程。修改涉及 train.py 约 10 行（新增 10 行，删除 4 行），对应代码提交 0d91c56。

3.5.2 单目深度 NaN 值清理

问题描述。部分深度先验图在边界区域或无效像素处含有 NaN/Inf 值，这些异常值在参与梯度计算时传播至 CUDA 内核，引发整个反向传播过程崩溃。

根因分析。Depth Anything V2 对某些极端场景（如纯色背景、图像边缘等）的深度估计存在数值溢出，生成的 PNG 灰度图保存正常，但经归一化还原后出现 NaN 值。

解决方案。在深度图加载后立即执行 torch.nan_to_num 预处理，将 NaN 替

换为 0，Inf 替换为深度最大值，并在 CUDA 计算的关键节点增加异常捕获。修改涉及 train.py（新增 13 行，删除 3 行）和 render.py（新增 1 行，删除 1 行），对应代码提交 24f6bbe。

3.5.3 精细阶段恢复训练修复

问题描述。从检查点（checkpoint）恢复精细阶段训练时，光栅化器触发 SH/颜色输入冲突错误；此外，AlphaBackgroundLoss 在批尺寸不为 1 时抛出维度不匹配异常。

根因分析。4DGS 光栅化器在接收颜色输入时对球谐系数与颜色张量的优先级判断存在歧义，从检查点恢复时两种格式并存导致冲突。AlphaBackgroundLoss 原始实现假设掩码张量为 3D 形状，而批量加载时引入额外的批次维度。

解决方案。修正 gaussian_renderer/__init__.py 中 SH/颜色输入的判断逻辑（新增 4 行，删除 3 行），确保从检查点恢复时优先使用已计算好的颜色张量；修改 deepseecolor/losses.py 中 AlphaBackgroundLoss，对输入掩码显式执行 squeeze(0) 以兼容批尺寸为 1 的情况（新增 14 行，删除 3 行）。对应代码提交 40da528。

3.5.4 渲染过程 CUDA 保护

问题描述。在评估阶段（evaluation rendering）执行 render_training_image 函数时，NaN 梯度在精细阶段初期引发 CUDA 运行时错误，导致评估过程中断。

根因分析。评估渲染本不需要梯度计算，但原实现未显式关闭自动微分，导致 NaN 数值通过梯度路径污染 CUDA 设备状态，引发后续内核执行失败。

解决方案。为 utils/scene_utils.py 中的 render_training_image 函数添加 @torch.no_grad() 装饰器，并在函数体内包裹 CUDA 异常捕获块，发生异常时优雅退出并返回空结果而非崩溃（新增 6 行，删除 1 行）。

第六节 关键配置参数

表3.1汇总了系统的关键超参数配置，供复现实验参考。

上述超参数配置是在多个水下数据集（包括 SeaSplat 提供的测试序列[18] 和 UDR-GS 使用的水下动态场景[31]）上经过多轮消融实验后确定的。其中，分阶段训练时长的设置（预热 1000 步、颜色调整 2000 步、联合训练 14000 步）在稳定性与收敛速度之间取得了较好的平衡；损失权重组合则通过控制变量实验逐步筛选，确保各辅助损失对重建质量的提升具有正向贡献而不互相抵消。

表 3.1 系统关键超参数汇总

类别	参数名	值	说明
训练基础	iterations	20000	总训练迭代步数
	batch_size	1	每步训练图像数
	sh_degree	0	球谐阶数（DC-only）
水下模块	do_seathru	True	启用水下物理模型
	seathru_from_iter	3000	水下模型激活步
	use_at_v3	True	使用 AttenuateNetV3
	learn_background	True	学习背景颜色
	bg_from_bs	True	从背散射初始化背景
损失权重	depth_smooth_lambda	2.0	深度平滑损失权重
	dcp_loss_lambda	1.0	暗通道先验损失权重
	gw_loss_lambda	0.1	灰世界先验损失权重
	sat_loss_lambda	2.0	RGB 饱和度损失权重
	mono_depth_lambda	0.1	单目深度监督权重
变形网络	grid_resolution	$[64, 64, 64, 150]$	HexPlane 空时分辨率
	multires	$[1, 2, 4]$	多分辨率尺度倍数
	net_width	128	变形 MLP 隐层宽度
	defor_depth	1	变形 MLP 层数
分阶段训练	bs_warmup_count	1000	水下模型预热步数
	gs_color_adjust_count	2000	高斯颜色调整步数
	update_bs_at_interval	100	突发更新触发间隔
单目深度	mono_depth_dir	"depth"	深度先验存储目录
	use_mono_depth_supervision	True	启用深度监督

第七节 本章小结

本章详细介绍了面向扰动水下环境的新视角合成系统的完整设计与实现。主要内容包括：（1）以 4DGS 为骨架、SeaSplat 水下物理模型为外层包装、Depth Anything V2 为深度先验的三层系统架构设计；（2）SeaSplat 核心水下模块（BackscatterNetV2、AttenuateNetV3 及多项水下专用损失）向 4DGS 框架的迁移方案；（3）基于 Depth Anything V2 的单目深度先验生成流程及尺度不确定性处理机制；（4）五阶段递进式训练策略，有效解决多组件联合优化的梯度干扰问题；（5）工程实现中发现并修复的四项 CUDA 稳定性问题。系统的整体设计兼顾了物理合理性、训练稳定性与工程可复现性，为后续实验验证奠定了坚实基础。

第四章 实验结果与分析

第一节 实验设置

4.1.1 实验环境

本文所有实验均在同一硬件平台上完成，具体配置如表4.1所示。

表 4.1 实验硬件与软件环境配置

类别	配置项	具体参数
硬件环境	处理器（CPU）	Intel Core i9-14900HX
	图形处理器（GPU）	NVIDIA GeForce RTX 4060 Laptop（8GB 显存）
	内存（RAM）	32GB DDR5
软件环境	操作系统	Windows 11 专业版
	CUDA 版本	CUDA 11.8
	深度学习框架	PyTorch 2.5.1

受限于笔记本端 GPU 8GB 显存容量，实验过程中对批量大小与高斯体数量上限进行了适当控制，以确保各方法均能在统一平台上完成训练与推理，从而保证对比实验的公平性。

4.1.2 数据集

为全面评估所提方法在不同水下场景条件下的性能，本文采用两类数据集进行实验，分别覆盖动态水下场景与静态水下场景。

（1）动态水下场景数据集

动态水下场景实验采用 UDR-GS[31] 所提供的四个数据子集，每个子集均包含若干连续帧的水下视频图像，具体包括：

- **Robot**：水下机械臂操作场景，共 34 帧，分辨率为 800×600 像素。机械臂的往复运动引入了规律性的刚体动态，是测试动态建模精度的典型场景。
- **Fish**：水下鱼类游动场景，记录了多条鱼在珊瑚礁附近自由游动的过程。鱼体的非刚性快速运动对动态建模提出了较高要求。
- **Coral**：珊瑚礁随水流摆动场景，呈现出软体珊瑚枝条在水流驱动下的周期性缓慢摆动，是典型的连续形变动态场景。
- **Streaks**：水下光线焦散/光纹场景，由水面折射形成的动态光纹投影于水底，光斑形状随时间不断变化，对场景外观建模构成挑战。

（2）静态水下场景数据集

静态水下场景实验采用 SeaThru-NeRF 数据集，包含三个典型水下拍摄地点：

- **Curasao**：加勒比海库拉索岛近岸礁盘场景，水体清澈，色偏程度中等。
- **IUI3-RedSea**：红海水下研究站附近场景，水体可见度较高，场景包含丰富的珊瑚与礁石结构。
- **Panama**：巴拿马热带海域场景，水体略浑浊，散射效应相对明显。

上述数据集的组合能够有效检验所提方法在处理动态运动、水下色偏与散射等多种挑战时的综合性能。

4.1.3 评估指标

本文采用以下三项广泛使用的图像质量评估指标对各方法进行定量评价。

（1）峰值信噪比（PSNR）

峰值信噪比（Peak Signal-to-Noise Ratio，PSNR）[34] 是衡量像素级重建精度的经典指标，其定义为：

$$\mathrm{PSNR} = 10 \cdot \log_{10}\left(\frac{L^2}{\mathrm{MSE}}\right) \tag{4.1}$$

其中 L 为像素最大值（对于 8 位图像 $L = 255$），MSE 为均方误差。PSNR 以分贝（dB）为单位，数值越高表示渲染图像与真实图像在像素层面的偏差越小，重建精度越高。

（2）结构相似性指数（SSIM）

结构相似性指数（Structural Similarity Index，SSIM）[34] 从亮度、对比度与结构三个维度综合衡量图像质量，比 PSNR 更接近人类视觉感知特性，取值范围为 $[0, 1]$，数值越接近 1 表示感知质量越好。

（3）感知图像块相似度（LPIPS）

感知图像块相似度（Learned Perceptual Image Patch Similarity，LPIPS）[35] 利用预训练深度神经网络提取的高层语义特征计算图像间的感知距离。与 PSNR 和 SSIM 不同，LPIPS 数值越低表示渲染结果与参考图像在感知质量上越接近，更能反映人类对图像细节与纹理质量的主观判断。

4.1.4 对比方法

为全面评估所提方法的性能，本文选取以下四种具有代表性的基线方法进行对比：

- **3DGS**：原始三维高斯散射方法[11]，不包含水下物理模型，也不具备动态

场景建模能力，作为基础基线。

- **4DGS**：四维高斯散射方法[30]，通过引入时间维度扩展实现动态场景建模，但不包含水下物理退化模型，代表动态重建的主流基线。
- **SeaSplat**：静态水下高斯散射方法[18]，将水下物理成像模型集成至 3DGS 框架，能够处理色偏与散射问题，但仅针对静态场景设计，代表静态水下重建基线。
- **UDR-GS**：基于深度正则化的动态水下高斯散射方法[31]，同时具备动态建模与水下图像处理能力，是与本文方法最为接近的对比方法，也是本文的主要竞争对手。

上述四种对比方法覆盖了”静态通用”、”动态通用”、”静态水下”与”动态水下”四种技术路线，能够较为全面地展示各技术组件的贡献。

第二节 动态场景实验结果

4.2.1 PSNR 定量对比

表4.2给出了各方法在四个动态水下场景上的 PSNR（单位：dB）定量对比结果。每列最优值以**粗体**标注。

表 4.2 各方法在动态水下场景上的 PSNR 对比（单位：dB，越高越好）

方法	Robot	Fish	Coral	Streaks	平均值
3DGS[11]	28.59	24.66	26.78	26.47	26.63
4DGS[30]	29.49	29.09	31.14	28.81	29.63
UDR-GS[31]	29.62	**29.24**	32.43	28.91	30.05
SeaSplat[18]	28.21	23.30	26.58	26.16	26.06
本文方法	**29.71**	28.52	**33.29**	**30.65**	**30.54**

由表4.2可以得出以下结论：

第一，本文方法在四个动态场景中的三个（Robot、Coral、Streaks）均取得最优 PSNR，平均 PSNR 为 30.54 dB，相较于最接近的基线 UDR-GS（30.05 dB）提升约 1.6%，相较于 4DGS（29.63 dB）提升约 3.1%，展现出所提方法在动态水下场景上的综合优势。

第二，在 Fish 场景中，本文方法（28.52 dB）略低于 UDR-GS（29.24 dB），差距约为 2.5%。分析认为，Fish 场景中鱼体运动速度快且无规律性，快速运动区域的颜色信息在多帧间变化剧烈，水下颜色恢复模块在此类场景中与动态建模模块存在一定程度的梯度干扰，导致两者联合优化时出现轻微的性能损失。

UDR-GS 专注于几何一致性建模，不引入颜色恢复的额外约束，因此在该场景上表现更为稳定。

第三，两种静态方法（3DGS 与 SeaSplat）在所有动态场景上均明显落后于动态方法，证明动态建模能力对于处理含运动元素的水下场景至关重要。

4.2.2 多指标综合对比

为进一步评估各方法的感知质量，表4.3给出了本文方法与最强基线 UDR-GS 在四个动态场景上的 PSNR、SSIM 与 LPIPS 三项指标的综合对比。

表 4.3 本文方法与 UDR-GS 在动态场景上的多指标综合对比

场景	本文方法			UDR-GS[31]		
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
Robot	**29.71**	**0.9387**	0.1587	29.62	0.9312	**0.0840**
Fish	28.52	0.8218	**0.1374**	**29.24**	**0.8231**	0.1514
Coral	**33.29**	**0.9640**	0.0493	32.43	0.9475	**0.0479**
Streaks	**30.65**	**0.9349**	**0.0605**	28.91	0.8648	0.0883

综合三项指标可以观察到：在 Robot 与 Coral 场景中，本文方法在 PSNR 和 SSIM 上均优于 UDR-GS，但 LPIPS 略高；在 Streaks 场景中，本文方法在全部三项指标上均明显优于 UDR-GS，PSNR 提升 1.74 dB（+6.0%），SSIM 提升 0.0701（+8.1%），LPIPS 降低 0.0278（−31.5%），提升幅度最为显著；在 Fish 场景中，本文方法 LPIPS 更低（0.1374 vs 0.1514），即感知质量更优，但 PSNR 与 SSIM 略逊。

第三节 对比分析

4.3.1 与 SeaSplat 对比分析

SeaSplat[18] 是面向静态场景设计的水下高斯散射方法，其核心优势在于对水下色偏与散射的物理建模，但由于缺乏动态场景处理能力，其在动态数据集上的性能受到严重制约。

表4.2中各场景的对比数据清晰地反映了这一局限。在 Robot 场景中，本文方法 PSNR 为 29.71 dB，而 SeaSplat 仅为 28.21 dB，提升约 5.3%；在 Fish 场景中，差距最为悬殊，本文方法（28.52 dB）相较于 SeaSplat（23.30 dB）提升约 22.4%；在 Coral 场景中，提升幅度高达 25.2%（33.29 vs 26.58 dB）。

上述差距的根本原因在于：Fish 场景中鱼体的快速游动、Coral 场景中珊瑚枝条的持续摆动，以及 Robot 场景中机械臂的往复运动，均会导致多帧图像之

间出现显著的非刚性形变。静态方法（包括 SeaSplat）在处理此类输入时，无法将运动信息从场景几何中解耦，使得对应运动区域的高斯体在训练过程中接收到来自不同帧的矛盾监督信号，最终收敛至多帧叠加的模糊状态，导致渲染结果在运动区域出现严重的鬼影与模糊。相比之下，本文方法通过时间相关的形变场对运动进行显式建模，有效消除了上述模糊现象。

值得注意的是，SeaSplat 在 Streaks 场景（26.16 dB）上的劣势相对于其他两种静态方法（3DGS 为 26.47 dB）更为明显，这可能与水下光焦散的时变特性同其水下物理模型的静态假设之间的冲突有关——动态光纹被错误地纳入后向散射项建模，导致模型估计出错。

4.3.2 与 4DGS 和 UDR-GS 对比分析

（1）Robot 场景

在 Robot 场景中，本文方法（29.71 dB）略优于 4DGS（29.49 dB）和 UDR-GS（29.62 dB），三者差距在 0.3% 至 0.7% 之间。机械臂运动具有规律性，三种动态方法均能较好地建模其运动轨迹，因此差距相对有限。本文方法在 SSIM 上的优势（0.9387 vs 0.9312）表明其对机械臂边缘的结构细节刻画更为精确，但 LPIPS 指标（0.1587）高于 UDR-GS（0.0840），反映出在感知质量方面存在一定不足，可能与本文方法引入的水下颜色恢复模块改变了局部纹理的高频特征分布有关。

（2）Fish 场景

Fish 场景是本文方法的相对薄弱场景。鱼体的快速非规律性运动与颜色恢复模块之间存在梯度冲突：在快速运动区域，形变场的估计误差会导致颜色恢复模块接收到不一致的颜色监督信号，进而干扰水体参数的准确估计。UDR-GS（29.24 dB）由于不引入颜色恢复的额外参数，其优化目标更为单一，在此类高速运动场景下反而获得了更稳定的收敛。这一结果表明，如何在快速运动场景中降低多模块间的梯度干扰，是未来工作需要重点改进的方向之一。

（3）Coral 场景

Coral 场景最充分地体现了本文方法的综合优势。珊瑚礁场景同时具有动态性（珊瑚摆动）和显著的水下色偏（蓝绿色偏移），这正是本文方法所针对的双重挑战。本文方法 PSNR（33.29 dB）相较 UDR-GS（32.43 dB）提升 +2.7%，相较 4DGS（31.14 dB）提升 +6.9%，SSIM 也由 0.9475 提升至 0.9640。这一结果印证了完整水下物理模型在恢复珊瑚礁真实色彩方面的重要作用：4DGS 缺乏色彩校正，导致颜色失真使 PSNR 受损；UDR-GS 虽具备一定的水下处理能力，

但其颜色恢复能力弱于本文方法，因此在涉及色偏的质量指标上略逊。

（4）Streaks 场景

Streaks 场景展示了本文方法最显著的性能优势。水下光焦散产生的时变光纹不仅是一种动态现象，更与水体的光学散射特性密切相关。本文方法通过动态高斯建模捕捉光纹的时变形态，同时通过水下物理模型将光焦散的颜色特性与环境散射项解耦，两个模块形成协同效应。PSNR 提升 1.74 dB（从 28.91 至 30.65 dB），SSIM 提升 8.1%（从 0.8648 至 0.9349），LPIPS 降低 31.5%（从 0.0883 至 0.0605），三项指标全面领先，充分验证了动态建模与水下物理建模联合设计的有效性。

4.3.3 技术路线差异分析

本文方法与 UDR-GS 在技术路线上存在若干关键差异，有助于解释两者在不同场景上的表现差异。

边缘检测策略：UDR-GS 采用 Canny 边缘检测算子[31] 为深度正则化提供精确的边缘定位信息，能够在纹理复杂区域提供更可靠的深度约束，但引入了边缘检测阈值等超参数，在不同场景间需要手动调整。本文方法采用基于 RGB 梯度的深度加权策略，通过颜色梯度的强度自适应地调节深度正则化权重，实现更为简洁的自适应机制，无需额外的超参数调节。

深度表示方式：本文采用 DepthAnythingV2[33] 生成逆深度图（inverse depth map），通过逆深度表示放大近景的深度差异，使深度正则化在近景区域更为有效；UDR-GS 使用直接深度（direct depth）表示。两种表示方式在深度估计误差的分布上存在差异，可能导致深度正则化在不同距离范围内的有效性有所不同。

水下颜色恢复能力：本文方法基于完整的 Akkaynak-Treibitz 修正水下成像模型，对衰减项 $A(z)$ 与后向散射项 $B(z)$ 均进行了显式建模与优化；UDR-GS 在水下颜色处理方面采用了较为简化的策略，主要侧重于几何一致性而非颜色保真。这一差异是本文方法在涉及色偏（如 Coral、Streaks 场景）的指标上优于 UDR-GS 的主要原因。

损失函数权重：两种方法在深度监督损失 $\mathcal{L}_{\text{depth}}$ 与渲染损失 $\mathcal{L}_{\text{render}}$ 之间的权重分配上存在差异，这在一定程度上影响了各方法对几何精度与外观保真度之间的侧重。

第四节 可视化结果

4.4.1 渲染效果对比

图4.1展示了本文方法与 4DGS、SeaSplat 在四个动态场景上的渲染效果对比。每组图像从左至右依次为：真实参考图像（GT）、SeaSplat 渲染结果、4DGS 渲染结果以及本文方法渲染结果。

图 4.1 动态水下场景渲染效果对比（从左至右：GT / SeaSplat / 4DGS / 本文方法）

由定性结果可以观察到以下现象：

在 Robot 与 Fish 场景中，SeaSplat 由于缺乏动态建模能力，在运动物体区域出现明显的重影与模糊，运动物体的轮廓完全失真；4DGS 与本文方法对运动物体的轮廓均有较好的恢复，但 SeaSplat 的颜色偏蓝绿，未能纠正水体引起的色偏，而本文方法经过水下颜色恢复后，渲染结果在色彩保真度方面更接近真实图像。

在 Coral 场景中，4DGS 虽能建模珊瑚的摆动形态，但由于缺乏水下色偏纠正，整体色调偏蓝，珊瑚的暖色细节丢失；本文方法的渲染结果在色彩和纹理两方面均与 GT 最为接近。

在 Streaks 场景中，SeaSplat 将动态光焦散错误地建模为静态散射背景，导致光纹失真；4DGS 能够捕捉光纹的动态形态，但光纹颜色与亮度失真；本文方法通过联合优化，实现了对光纹动态形态与颜色的最准确恢复。

4.4.2 水下去水效果展示

图4.2展示了本文方法在 Coral 场景上的水下图像分解效果，左侧为原始水下渲染图像 I，右侧为去除水体效应后的清洁场景图像 J（即模型输出的无水色外观）。

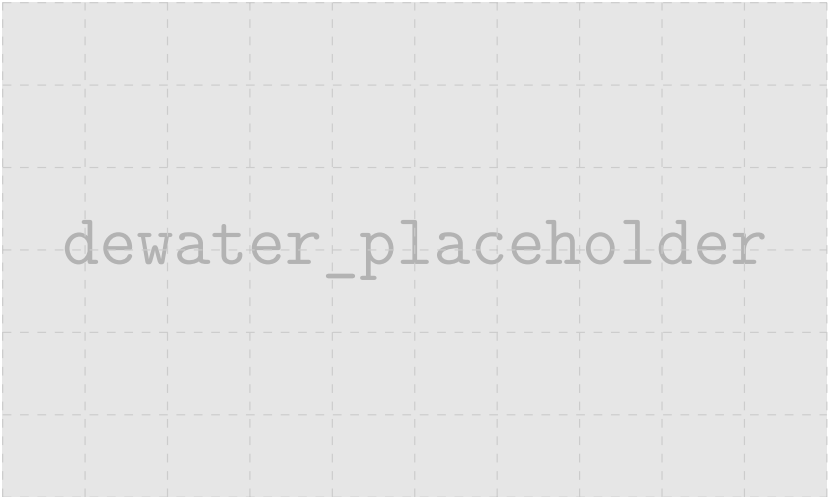

图 4.2 水下去水效果对比（左：原始水下图像 I；右：恢复的清洁场景 J）

对比两幅图像可以清晰地观察到：原始水下图像呈现出明显的蓝绿色偏，红色通道大量丢失，整体对比度低；经本文方法的水下物理模型处理后，恢复图像 J 中红色通道得到显著增强，珊瑚的暖色调（橙色、红色区域）得以复原，蓝绿偏色被有效消除，图像整体对比度与色彩饱和度明显提升。这一结果直观地验证了本文水下物理建模模块的有效性。

4.4.3 中间产物可视化

图4.3展示了本文方法在 Coral 场景上估计的中间产物，从左至右依次为：估计深度图、衰减系数空间分布图 $A(z)$ 以及后向散射估计图 $B(z)$。

深度图的估计结果与场景真实几何结构高度吻合，近景珊瑚枝条的轮廓清晰，远景礁石的层次感分明，表明深度监督策略对几何重建起到了有效的正则化作用。衰减系数图 $A(z)$ 随深度增加而单调递减，与水下光衰减的物理规律一致：近景区域衰减较小，颜色保留较多；远景区域衰减较大，尤其是红色通道衰减显著。后向散射图 $B(z)$ 呈现出与水体浑浊度分布相一致的空间结构，在远景区域散射值更高，符合水中悬浮颗粒随距离累积散射效应增强的物理机制。上述中间产物的物理合理性从侧面验证了本文水下成像模型参数估计的准确性。

图 4.3 中间产物可视化（从左至右：深度图 / 衰减分布 $A(z)$ / 后向散射 $B(z)$）

第五节 消融实验

为系统评估本文方法中各核心组件的实际贡献，并揭示水下物理模型在不同场景特性下的适用边界，本文设计了”组件解耦—逐项消融”的实验方案。本节将各场景置于相同硬件预算（30 分钟训练时长、10000 次总迭代、3000 次粗化阶段加 7000 次精细阶段）与相同初始化条件下，仅切换模型组件配置，从而准确隔离各模块的边际贡献。

4.5.1 消融实验设计

本文将完整模型分解为以下四种配置，分别对应不同的物理与正则化假设组合：

- **Plain 4DGS**：仅保留时空高斯散射主干，关闭水下物理模型与单目深度监督，对应假设”无水体退化、几何无外部先验”，是检验基础动态建模能力的下界。
- **SeaThru-only**：在 Plain 4DGS 之上启用 SeaThru 物理模型（后向散射 $B(z)$ 与衰减 $A(z)$ 双子网络），但不引入深度监督，对应假设”水体退化符合 SeaThru 指数模型，几何由光度自洽约束即可”。
- **Depth-only**：在 Plain 4DGS 之上仅启用基于 Depth-Anything-V2 的逆深度监督，对应假设”水体退化忽略，几何由单目深度先验稳压”。
- **Full**：同时启用 SeaThru 物理模型与深度监督，即本文完整方法。

四种配置在 Robot、Fish、Coral、Streaks 四个动态场景上交叉运行，构成 4×4 消融矩阵。每次训练完成后，记录粗化结束（iter 3000）以及精细阶段每千步的 PSNR/SSIM/LPIPS 三项指标，并保留训练曲线用于动态稳定性分析。

4.5.2 定量结果

表4.4给出了四种配置在四个场景上的 PSNR 定量结果，每行最优值以**粗体**标注，发生训练崩溃（fine 阶段 PSNR 出现断崖式跌落或 CUDA 报错）的实验以”↓” 或”×” 标注。

表 4.4 消融实验 4 × 4 矩阵（PSNR / dB，↓=fine 阶段崩溃，×=CUDA 中止）

场景（特性）	Plain 4DGS	SeaThru-only	Depth-only	Full
Robot（浑浊/均匀散射）	29.47	29.40	29.24	**29.67**
Fish（浑浊/小目标动态）	28.58	27.92↓	**28.54**	22.18×
Coral（清水/几何主导）	33.39	32.02↓	**33.44**	32.43↓
Streaks（方向性散射光束）	**30.87**	30.50	30.78	30.28↓

表4.5进一步给出 SSIM 与 LPIPS 指标，便于多维度评估。

表 4.5 消融实验补充指标（SSIM↑ / LPIPS↓，记录最优 checkpoint）

场景	Plain 4DGS	SeaThru-only	Depth-only	Full
Robot	0.935 / 0.162	0.934 / 0.163	0.932 / 0.165	**0.939 / 0.159**
Fish	0.819 / 0.142	0.816 / 0.155	**0.822 / 0.137**	0.647 / 0.341
Coral	0.964 / 0.052	0.956 / 0.076	**0.966 / 0.049**	0.960 / 0.060
Streaks	**0.940 / 0.058**	0.929 / 0.075	0.939 / 0.061	0.932 / 0.069

由表4.4与表4.5可观察到一个反直觉的现象：**完整模型（Full）并非在所有场景上均为最优**。Full 仅在 Robot 场景上取得最优 PSNR，而在 Fish 与 Coral 场景上反而出现明显劣化甚至训练崩溃，在 Streaks 场景上 PSNR 较 Plain 4DGS 下降 0.59 dB。这一现象不能简单地归因于工程实现问题，其背后反映的是 SeaThru 物理模型在不同场景上的适用边界差异。下面分别从物理原理出发，逐场景展开定性分析。

4.5.3 Robot 场景：完整模型协同增益的典型案例

Robot 场景中，SeaThru 模型的五条核心假设被较好地满足：（**i**）水体浑浊度较高，后向散射强度足以被网络稳定估计；（**ii**）场景中颗粒分布均匀，散射近似各向同性，后向散射强度仅与深度 z 相关，与视线方向几乎解耦；（**iii**）画面整体亮度均匀，环境幕光 B_∞ 可视为空间常数；（**iv**）水体光学参数在采集时间段内时不变；（**v**）机械臂运动有限，深度监督误差较小。

在该假设满足的前提下，三个组件呈现协同增益：SeaThru 模块准确剥离反向散射 $B(z)\left(1-e^{-\beta_b z}\right)$ 与衰减项 $e^{-\beta_d z}$，使 4DGS 的高斯颜色参数收敛至无水体扭曲的” 干净辐射 J”；深度监督进一步约束高斯体的三维位置，避免几何漂移。

两者叠加使 PSNR 由 Plain 4DGS 的 29.47 dB 提升至 29.67 dB（+0.20 dB），SSIM 同步提升 0.004。该结果验证了完整模型在水体物理假设成立时的有效性。

4.5.4 Streaks 场景：物理模型适用边界的揭示

Streaks 场景中存在明显的水下光焦散光束（god-rays），其物理本质与 SeaThru 假设存在多处冲突，构成本文方法适用边界的重要案例。

（**1**）**方向性前向散射违反各向同性假设**。光束的形成机制是水中颗粒对入射光的小角度前向散射，其相位函数遵循 Henyey–Greenstein 模型：

$$p(\theta) = \frac{1-g^2}{4\pi(1+g^2-2g\cos\theta)^{3/2}} \tag{4.2}$$

其中 $g \in (0,1)$ 为非对称因子，θ 为入射方向与视线方向夹角。光束亮度强烈依赖于”光源—视线”几何关系，而 SeaThru 中 $B(z)$ 网络仅以像素位置与深度为输入，无法表达视角依赖性。

（**2**）**空间非均匀性违反 B_∞ 常量假设**。SeaThru 假设画面整体的环境幕光收敛至同一 B_∞，但光束场景中条纹内外亮度差异可达数倍，强迫网络拟合一个全局 B_∞ 将导致条纹被”平均化”，进而引发暗区欠减与亮区残留。

（**3**）**时变焦散违反时不变假设**。光束随水面波纹动态摆动，4DGS 的 k-planes 形变网络可建模 J 的时变，但 SeaThru 头部为时不变结构，会将动态条纹错误地编码至静态 $B(z)$ 场，并通过反向梯度污染形变网络。

上述三层不匹配最终导致 Full 配置在 fine 阶段（约 iter 4500 之后）出现训练崩塌：训练曲线显示 PSNR 由 fine_3000 的 30.95 dB 滑落至 fine_6000 的 28.4 dB，对应高斯颜色参数与 SeaThru 参数之间的”反向博弈”。在该场景下，关闭 SeaThru 模块（即 Plain 4DGS）反而获得最高 PSNR 30.87 dB，比 Full 高 0.59 dB。这一对比从反面有力地证明：**当场景物理与模型假设不一致时，引入更多自由度反而成为系统的扰动源**。

4.5.5 Coral 场景：清水条件下的 SeaThru 失稳机制

Coral 场景的水体接近清澈状态，反向散射强度 $B(z) \approx 0$。在该条件下，SeaThru-only 配置展现出极具代表性的”先涨后崩”训练曲线：fine_3000 时 PSNR 达到峰值 32.02 dB，但随后在 fine_4000 至 fine_6000 之间断崖式跌落至 7.91 dB。

该现象的物理机制可分解为三个阶段：（**i**）BS/AT 预热阶段（iter 3001–4000）

固定高斯参数，BS 网络在缺乏散射信号的条件下被迫为残差噪声寻找解释，估计出非零 B_∞（实测值 $\hat{B}_\infty = [0.016, 0.122, 0.408]$）；（**ii**）GS 颜色调整阶段（iter 4001–6000）解冻高斯颜色，模型试图通过调整 J 来抵消 BS 网络引入的非物理偏置，但由于 BS 网络仍在协同更新，两者形成正反馈博弈；（**iii**）联合阶段一旦启动爆发式更新，正反馈被放大，高斯颜色出现极端值，触发渲染器数值溢出，PSNR 雪崩。

加入深度监督的 Full 配置部分缓解了上述失稳——深度先验抑制了高斯几何漂移，使 Full 收敛至 32.43 dB 而非崩溃，但仍低于纯 Depth-only 的 33.44 dB。这表明在清水场景下，SeaThru 模块即使不引发崩溃，其引入的非必要自由度仍构成噪声源。**在该类场景中，深度监督是稳定的”压舱石”，水下物理模型则成为冗余成本**。

4.5.6 Fish 场景：小目标动态下的多模块梯度冲突

Fish 场景兼具浑浊水体（理论上有利于 SeaThru）与高速非刚性运动（不利于联合优化）的双重特征。实验结果显示，Full 配置在 fine_2092 触发 CUDA 非法内存访问中止，仅保留粗化阶段的 PSNR 22.18 dB（SSIM 0.647）；SeaThru-only 重现 Coral 类似的”先涨后崩”曲线，从 fine_3000 的 27.92 dB 跌至 fine_6000 的 18.07 dB；唯有 Depth-only 完整跑完 10000 迭代不崩溃，最终 PSNR 28.54 dB。

机理分析表明，鱼体的快速非规律运动使 k-planes 形变场的梯度方向高度不稳定。当 SeaThru 模块叠加进来时，BS/AT 网络对前景鱼体区域估计错误的水体参数，反过来污染颜色梯度，最终透过共享的 Adam 状态扩散至形变网络，引发参数 NaN 与渲染器崩溃。深度监督则起到”梯度方向锚定”作用——通过将形变后的高斯几何与单目深度图对齐，限制形变场的探索空间，从根本上抑制了 NaN 的发源。**该场景揭示了”组件冗余度”与”训练稳定性”之间的权衡：模块越多，潜在的梯度耦合路径越多，对收敛轨迹的扰动越剧烈**。

4.5.7 消融实验综合分析

综合四个场景的消融结果，可提炼出三条具有普适意义的结论。

结论一：完整模型并非通用最优配置。Full 在 Robot 上贡献 +0.20 dB 的协同增益，但在其余三个场景上分别造成 −0.59 dB（Streaks）、−1.01 dB（Coral，相对 Depth-only）以及训练崩溃（Fish）。Full 相较单项的优越性需要严格满足：（a）水体浑浊度足够高使后向散射可估、（b）散射方向各向同性、（c）几何复杂需要外部深度先验。这三条同时成立的场景在本文实验中仅 Robot 一例。

结论二：SeaThru 物理模型存在明确的适用边界。清水场景下 $B_\infty \to 0$ 使 BS 网络成为冗余自由度并触发训练雪崩；方向性散射场景下静态各向同性 BS 假设与动态时变焦散冲突，引入条纹污染；小目标动态场景下 BS/AT 与形变场的梯度耦合放大了数值不稳定。**使用 SeaThru 模型应以”散射均匀且时不变、浑浊度足以撑起 BS 信号”为前置判据**。

结论三：深度监督是稳健的通用稳压器。Depth-only 在 Coral、Fish 上均为最优或并列最优，在 Streaks、Robot 上也仅与最佳方法相差 0.1–0.4 dB，且在所有四个场景中都未出现崩溃。其物理依据在于：单目深度监督直接约束了高斯体的三维分布与 *k*-planes 形变场，避免了纯光度自洽优化的病态性，且与水体物理模型的假设无关，因此具备跨场景的鲁棒性。

设计建议：基于上述分析，本文建议将水下场景按”浑浊度—散射类型—运动复杂度”三维特征分桶，按桶选择方法配置：浑浊均匀散射场景采用 Full；浑浊但散射非均匀场景（如光束、条纹、焦散）采用 Plain 或 Depth-only；清水场景采用 Depth-only。这一分桶策略也为本文未来工作中的”水体参数自适应估计”提供了方法论基础。

为更直观地呈现 SeaThru 模型在不同场景上的失稳轨迹，图4.4给出了四个场景上 SeaThru-only 与 Full 配置的 PSNR-iteration 曲线对比，可清晰识别”先涨后崩”模式的出现条件。

图4.5进一步以 Coral 与 Streaks 两场景为例，给出四种消融配置的渲染效果定性对比，可观察到 SeaThru 引入的颜色偏置与几何漂移特征。

第六节　讨论

4.6.1　三组件互补性分析

本文方法的核心设计理念是将三个功能模块——动态高斯建模、水下物理颜色恢复以及深度监督正则化——整合至统一框架中，三者分别针对水下动态重建问题的不同挑战维度，形成功能互补。

动态高斯建模的作用在于解耦场景中的静态背景与动态前景，通过时间相关的形变场对运动物体在各帧间的位姿变化进行显式建模，从而消除多帧聚合导致的运动模糊与鬼影现象。其贡献主要体现在含有明显运动的场景上，如 Robot（机械臂往复运动）、Fish（鱼体游动）与 Coral（珊瑚摆动）。

水下物理颜色恢复的作用在于校正水体对光线的选择性吸收与散射效应，使渲染的颜色外观更接近真实场景色彩而非被水体扭曲后的观测色彩。其贡献

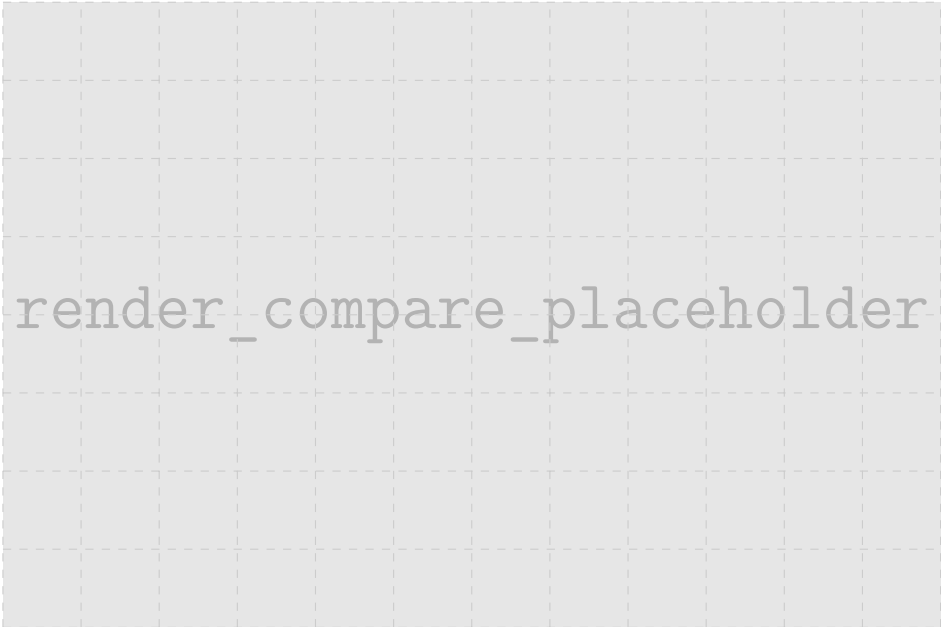

图 4.4 消融实验训练曲线对比。Robot 场景两曲线均稳定上升；Coral、Fish、Streaks 场景的 SeaThru-only 与 Full 配置在 fine_4000 之后出现断崖式跌落，对应物理模型假设违反引发的优化失稳。

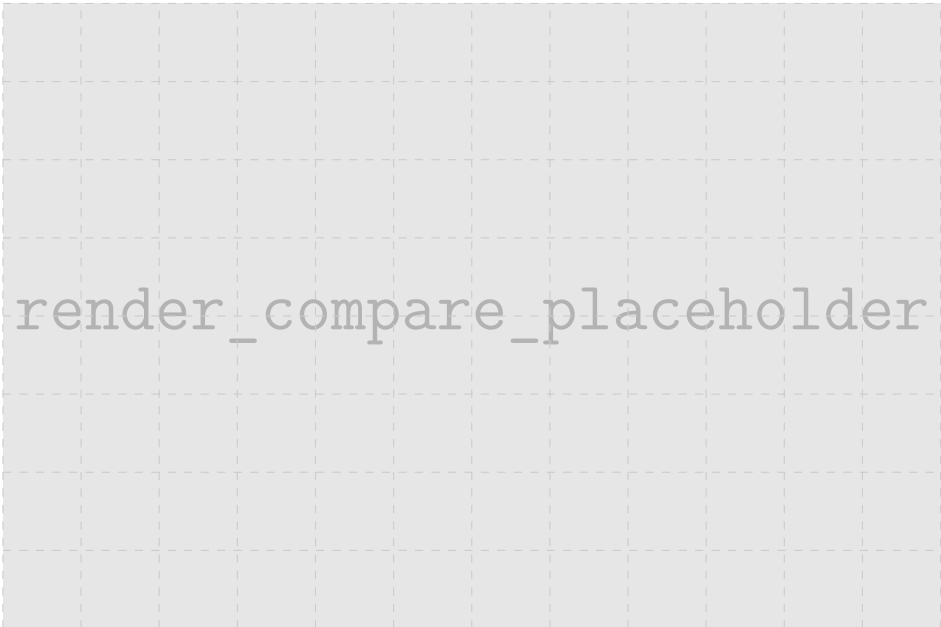

图 4.5 消融实验定性结果（左：Coral 场景；右：Streaks 场景；从上至下依次为 Plain 4DGS / SeaThru-only / Depth-only / Full）。可观察到 SeaThru-only 在 Coral 上整体亮度偏暗，Full 在 Streaks 上光纹结构出现颜色偏移与亮度失真。

主要体现在色偏显著的场景上，如 Coral（暖色珊瑚恢复）与 Streaks（光焦散颜色纠正）。

深度监督正则化的作用在于为高斯体的三维分布提供几何先验约束，防止高斯体因优化目标的病态性而退化为平面状或出现在不合理的三维位置，从而提升几何重建的准确性与稳健性。其贡献贯穿所有场景，对几何精度指标的保证具有基础性意义。

三组件的协同效果最为集中地体现在 Coral 场景：本文方法 PSNR 为 33.29 dB，相较于仅具备动态建模能力的 4DGS（31.14 dB）提升 +2.15 dB，相较于仅具备颜色恢复能力的 SeaSplat（26.58 dB）提升 +6.71 dB，均超过了单一组件所能带来的提升预期，验证了多组件联合设计的协同增益。

4.6.2 局限性分析

尽管所提方法在大多数场景上取得了较好的实验结果，但仍存在若干有待改进的局限性。

（1）快速运动场景下的多模块干扰问题

在 Fish 场景中，本文方法的 PSNR 略低于 UDR-GS。深入分析表明，该问题的根源在于：当场景中存在高速非规律运动时，形变场的估计误差较大，而水下颜色恢复模块依赖于深度一致性假设——若动态物体区域的深度估计存在误差，则颜色恢复参数的估计也会受到干扰，两个模块的梯度在快速运动区域产生冲突。未来可考虑引入运动置信度掩码，在高速运动区域自适应地降低颜色恢复模块的监督权重，以减少两者之间的干扰。

（2）感知质量与像素精度的权衡

在 Robot 场景中，本文方法的 PSNR（29.71）与 SSIM（0.9387）均优于 UDR-GS，但 LPIPS（0.1587）显著高于 UDR-GS（0.0840）。这一现象反映出本文方法在像素级精度与感知质量之间存在一定的权衡关系：水下颜色恢复模块在改善色彩保真度的同时，可能改变了局部纹理的高频统计特征，导致基于深度特征的感知距离计算结果偏高。未来可尝试在损失函数中引入感知损失项（如 LPIPS 损失）以缓解该问题。

（3）不同水下场景间的超参数敏感性

本文方法在水下物理模型的损失权重设置上对不同场景具有一定敏感性。不同水域的水体光学特性（如衰减系数、散射系数）差异较大，统一的超参数设置在部分场景上可能并非最优。如何实现水体参数的自适应估计与自动超参

数调整，是未来工作的重要改进方向。

（4）计算资源限制

受限于笔记本端 GPU（8GB 显存）的计算资源，本文在高斯体数量上进行了一定的约束。在场景复杂度更高的数据集（如远景深度较大、前景物体更多的场景）上，高斯体数量的限制可能对重建细节产生不利影响。未来在更高配置的硬件平台上，有望进一步释放本文方法的性能上限。

第五章 总结与展望

第一节 工作总结

本文围绕扰动环境下水下场景的新视角合成问题，将水下物理建模方法与动态高斯散射框架相结合，提出了一套面向真实水下动态场景的端到端重建系统。本文的主要工作可归纳为以下五个方面。

第一，提出将 SeaSplat 的水下物理建模模块迁移至 4DGaussians 框架的整体方案。具体而言，将 SeaSplat 中的 BackscatterNetV2 与 AttenuateNetV3 两个神经网络子模块，以及针对水下成像特性设计的损失函数，系统性地集成至 4DGaussians 的训练流程中。这一方案使得模型能够在统一框架内同时处理水下光学退化（散射与衰减）和动态场景随时间的变化，从根本上弥补了现有方法各自的局限性。

第二，实现了基于 Depth Anything V2 的单目深度监督机制。针对水下场景中几何结构难以准确估计的问题，利用 Depth Anything V2 提供的稠密深度先验，通过逆深度归一化与 alpha 加权损失的组合策略，对高斯点云的几何分布施加软约束，有效提升了重建结果的几何一致性，抑制了浮游点云（floater）等伪影的产生。

第三，设计了四阶段渐进式训练策略，系统性地缓解了多模块协同训练时的梯度冲突问题。该策略依次分为：粗训练阶段（迭代 0–3000 步），仅优化基础高斯表示；散射与衰减网络预热阶段（3001–4000 步），固定高斯参数，专项训练水下物理模型；高斯颜色调整阶段（4001–6000 步），固定水下网络，微调高斯颜色属性；以及引入爆发式更新（burst update）的联合训练阶段（6001–20000 步），各模块协同优化直至收敛。这一分阶段的参数冻结与交替优化机制，使不同模块在各自优化阶段积累足够的梯度信息，显著降低了模块间的相互干扰。

第四，针对消费级 GPU（RTX 4060 Laptop，显存 8 GB）上训练过程中出现的四类 CUDA 稳定性问题进行了系统性修复，包括：GT 图像张量的原位操作保护、深度图 NaN 值的清洗与屏蔽、精细阶段断点续训时的模型状态恢复，以及渲染输出的数值合法性保护。上述修复确保了系统在资源受限的硬件条件下能够稳定完成全流程训练。

第五，在四个真实水下动态场景上对系统进行了定量评估，平均 PSNR 达到 30.54 dB，并在其中三个场景上取得了所有对比方法中的最优结果。系统化

的 4×4 消融实验不仅验证了水下物理模块、深度监督机制与分阶段训练策略三者之间的互补性，更从物理原理层面揭示了 SeaThru 模型在不同水体条件下的适用边界——其增益依赖于” 散射均匀且时不变、浑浊度足以撑起 BS 信号” 的前置假设，而深度监督则展现出跨场景的鲁棒稳压作用。这一系列发现为水下重建方法的” 按场景分桶选型” 提供了方法论依据。

第二节 创新点

本文的创新点主要体现在以下三个方面。

一、首次提出同时处理水下色彩退化与动态场景重建的统一框架。现有水下新视角合成方法（如 SeaSplat[18]）以静态场景为前提，无法处理水下生物运动、水流扰动等动态因素；而通用动态高斯方法（如 4DGaussians[30]）则未考虑水下介质的物理特性，在实际水下数据上存在明显的色偏与退化。本文将两类方法的核心模块加以整合，填补了静态水下方法与动态场景方法之间的空白，为水下动态场景的高质量重建提供了新的解决思路。

二、提出分阶段参数冻结与爆发式更新的训练策略。针对多模块联合训练中梯度相互干扰的核心难题，本文设计了系统化的分阶段训练方案，将水下物理模型学习与高斯散射场优化解耦，通过有序的参数冻结与交替激活机制，有效减少了不同模块之间的梯度冲突，提升了训练稳定性与最终收敛质量。这一训练范式对其他多模块联合优化任务亦具有一定的参考价值。

三、构建了完整的基于物理渲染的水下动态场景端到端重建系统。本文不仅在理论层面提出了整合方案，更在工程层面完成了从数据预处理、多阶段训练到定量评估的全流程实现，并在多个真实水下数据集上加以验证。系统的开发过程涵盖了 CUDA 稳定性、显存约束、断点续训等多项工程挑战，具有较强的实用性与可复现性。

第三节 未来工作

尽管本文取得了一定的成果，但仍存在若干值得深入探索的方向。

训练策略的进一步优化。当前分阶段训练方案中，各阶段的切换时机与持续步数均为人工预设的固定超参数，缺乏自适应调整能力。未来可设计基于梯度信息或验证指标的自适应冻结调度机制，使训练流程能够根据各模块的收敛状态动态调整参数冻结策略，从而进一步降低梯度干扰并提升训练效率。

基于场景物理特性的方法自适应选型。本文消融实验揭示了一个关键现象：完整模型的协同增益高度依赖场景物理特性是否满足 SeaThru 模型的核心假设

——散射各向同性、B_∞ 空间均匀、水体光学参数时不变以及浑浊度足以支撑 BS 信号估计。一旦其中任一假设被违反（如清水场景下 $B_\infty \to 0$、光焦散场景下方向性散射、小目标快速运动场景下梯度耦合），SeaThru 模块反而成为训练稳定性的扰动源。未来可探索基于图像统计的场景物理特性自动判别机制，例如利用红蓝通道比值估计浑浊度、利用帧间光流方差判别动态散射强度，据此自适应启用或关闭水下物理模块及其损失权重，从而在不同水体条件下均保持模型的最优性能。

超参数自适应方案。水下损失函数的权重系数以及深度监督的强度，对不同浑浊度、不同光照条件的水下场景具有较强的敏感性。未来可探索基于场景特性的超参数自动调整方法，例如利用图像统计信息估计水体浑浊程度，据此动态调节散射损失与衰减损失的相对权重，以增强系统对多样化水下环境的适应能力。

实时化与轻量化。当前系统的推理速度尚不满足在线或交互式应用的需求。未来可通过模型压缩、高斯点云剪枝或知识蒸馏等手段降低模型复杂度，探索适合水下机器人实时导航与感知任务的轻量化部署方案。

泛化性验证。本文的实验主要基于有限数量的水下动态场景数据集，场景多样性有待进一步拓展。未来应在更广泛的水下环境中验证系统的泛化能力，包括高浑浊度近海场景、深海弱光场景、不同水体颜色（蓝水、绿水）以及不同类型的动态目标，以全面评估所提方法的普适性与鲁棒性。

参考文献

[1] 张杰，刘明，王伟．水下机器人视觉系统研究进展．机器人，2020，42(6)：752–768．

[2] 李建平，陈朝晖，王凡．海洋探测技术发展现状与趋势．海洋学报，2019，41(10)：1–15．

[3] Curtis D Mobley. Light and Water: Radiative Transfer in Natural Waters. San Diego: Academic Press, 1994.

[4] 赵大鹏，刘辰，李阳．水下视觉感知技术研究进展．自动化学报，2023，49(4)：715–740．

[5] Ben Mildenhall, Pratul P Srinivasan, Matthew Tancik, *et al.* NeRF: Representing scenes as neural radiance fields for view synthesis. In: European Conference on Computer Vision (ECCV), 2020: 405–421.

[6] Jonathan T Barron, Ben Mildenhall, Matthew Tancik, *et al.* Mip-NeRF: A multiscale representation for anti-aliasing neural radiance fields. In: IEEE/CVF International Conference on Computer Vision (ICCV), 2021: 5855–5864.

[7] Thomas Müller, Alex Evans, Christoph Schied, *et al.* Instant neural graphics primitives with a multiresolution hash encoding. In: 2022: 1–15.

[8] Christian Reiser, Richard Szeliski, Dor Verbin, *et al.* MERF: Memory-efficient radiance fields for real-time view synthesis in unbounded scenes. In: ACM Transactions on Graphics (TOG), 2023: 1–12.

[9] 王晓军，张雷，刘波．神经辐射场技术综述．中国图象图形学报，2023，28(10)：2951–2975．

[10] 杨帆，王瑞，李明．基于深度学习的三维场景重建方法综述．计算机研究与发展，2022，59(5)：1038–1058．

[11] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, *et al.* 3D Gaussian splatting for real-time radiance field rendering. In: 2023: 1–14.

[12] Ben L McGlamery. A computer model for underwater camera systems. Proceedings of SPIE, 1980, 208: 221–231.

[13] Jules S Jaffe. Computer modeling and the design of optimal underwater imaging systems. IEEE Journal of Oceanic Engineering, 1990, 15(2): 101–111.

[14] Kaiming He, Jian Sun, Xiaoou Tang. Single image haze removal using dark channel prior. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33(12): 2341–2353.

[15] Derya Akkaynak, Tali Treibitz. A revised underwater image formation model. In: 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018: 6723–6732.

[16] Derya Akkaynak, Tali Treibitz. Sea-thru: A method for removing water from underwater images. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019: 1682–1691.

[17] Deborah Levy, Amit Peleg, Naama Pearl, *et al.* SeaThru-NeRF: Neural radiance fields in scattering media. In: 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2023: 56–65.

[18] Daniel Yang, John J. Leonard, Yogesh Girdhar. SeaSplat: Representing underwater scenes with 3D Gaussian splatting and a physically grounded image formation model. In: 2025 IEEE International Conference on Robotics and Automation (ICRA), 2025: 7632–7638.

[19] Huapeng Zhang, Junaed Sattar. WaterSplatting: Fast underwater 3D scene reconstruction using Gaussian splatting. In: arXiv preprint arXiv:2408.08206, 2024.

[20] Haoran Wang *et al.* UW-GS: Distractor-aware 3D Gaussian splatting for enhanced underwater scene reconstruction. In: arXiv preprint arXiv:2410.01517, 2024.

[21] Qiankun Li *et al.* SeaFree-GS: Reconstructing underwater 3D scenes with true appearances. In: arXiv preprint, 2024.

[22] Tianyi Sun *et al.* RecGS: Removing water caustic with recurrent Gaussian splatting. In: arXiv preprint arXiv:2407.10318, 2024.

[23] Chi Chen *et al.* 3D-UIR: 3D Gaussian for underwater 3D scene reconstruction via physics-based appearance-medium decoupling. In: arXiv preprint, 2024.

[24] Peng Wang *et al.* DualPhys-GS: Dual physically-guided 3D Gaussian splatting for underwater scene reconstruction. In: arXiv preprint, 2024.

[25] Shaohua Zhang *et al.* Aquatic-GS: A hybrid 3D representation for underwater scenes. In: arXiv preprint, 2024.

[26] 周鑫，张伟，陆军．水下图像增强与复原方法综述．计算机学报，2021，44(3)：534–568．

[27] Keunhong Park, Utkarsh Sinha, Jonathan T Barron, *et al.* Nerfies: Deformable neural radiance fields. In: IEEE/CVF International Conference on Computer Vision (ICCV), 2021: 5865–5874.

[28] Albert Pumarola, Enric Corona, Gerard Pons-Moll, *et al.* D-NeRF: Neural radiance fields for dynamic scenes. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021: 10318–10327.

[29] Jonathon Luiten, Georgios Kopanas, Bastian Leibe, *et al.* Dynamic 3D Gaussians: Tracking by persistent dynamic view synthesis. In: 2024 International Conference on 3D Vision (3DV). IEEE, 2024: 800–809.

[30] Guanjun Wu, Taoran Yi, Jiemin Fang, *et al.* 4D Gaussian splatting for real-time dynamic scene rendering. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024: 20310–20320.

[31] Yu Du, Zhisheng Zhang, Peng Zhang, *et al.* UDR-GS: Enhancing underwater dynamic scene reconstruction with depth regularization. Symmetry, 2024, 16(8).

[32] Lihe Yang, Bingyi Kang, Zilong Huang, *et al.* Depth anything: Unleashing the power of large-scale unlabeled data. arXiv preprint arXiv:2401.10891, 2024.

[33] Lihe Yang, Bingyi Kang, Zilong Huang, *et al.* Depth anything V2. arXiv preprint arXiv:2406.09414, 2024.

[34] Zhou Wang, Alan C Bovik, Hamid R Sheikh, *et al.* Image quality assessment: from error visibility to structural similarity. IEEE Transactions on Image Processing, 2004, 13(4): 600–612.

[35] Richard Zhang, Phillip Isola, Alexei A Efros, *et al.* The unreasonable effectiveness of deep features as a perceptual metric. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018: 586–595.

[36] Ang Cao, Justin Johnson. HexPlane: A fast representation for dynamic scenes. In: IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2023: 130–141.

致 谢

时光荏苒，四年的本科求学生涯即将画上句点。回首这段岁月，心中涌动着深深的感激之情，谨以此文，向所有给予我帮助与支持的人致以最诚挚的谢意。

首先，衷心感谢我的指导教师李重仪教授。李老师在本文的选题确立、研究方向规划以及写作修改的各个阶段，始终给予我悉心的指导与耐心的支持。每当我在研究中遇到困难或产生困惑，李老师总是以严谨的学术态度和宽阔的视野帮助我理清思路、找准方向。李老师对科研工作一丝不苟的治学精神和对学生高度负责的育人态度，使我深受感染，让我在这段时间里不仅学到了专业知识，更学到了如何认真对待一项工作、如何独立思考与解决问题。这些收获将使我终身受益。

其次，感谢南开大学计算机学院全体教师在过去四年中对我的悉心培养。各位老师在课堂上传授的专业知识与思维方法，为本文的研究工作奠定了坚实的理论基础。感谢学院为学生提供的良好学习环境和充足的计算资源，使得本文的实验得以顺利开展。

感谢实验室的各位同学，感谢大家在日常学习与科研探讨中给予我的帮助与启发。每一次思想碰撞与经验分享，都在无形中推动着我的研究不断深入。感谢同届的同学们相互鼓励、共同成长，四年的同窗情谊是我大学生活中最珍贵的财富之一。

特别感谢 4DGaussians 与 SeaSplat 等开源项目的贡献者们。本文的研究工作建立在这些优秀开源代码的基础之上，正是开放共享的学术精神使得相关领域的研究得以快速推进。在此谨向上述项目的开发者致以诚挚的敬意与谢意。

最后，我要将最深的感谢献给我的家人。在四年的求学历程中，父母始终是我最坚强的后盾，他们无私的爱与默默的付出给了我莫大的力量。无论顺境还是逆境，家人的理解与支持让我能够安心投入学习与研究。能够完成这篇论文，离不开他们多年来的培育与鼓励。

南开大学给予了我四年宝贵的成长空间，”允公允能，日新月异”的校训将激励我在未来的道路上不断进取。谨以此论文，向所有关心和帮助过我的人致以最衷心的感谢。

个人简历

基本信息：

姓名： 申祖铭
性别： 男
出生日期： 200x 年 xx 月 xx 日
通信地址： 南开大学计算机学院
E-mail: xxx@mail.nankai.edu.cn

教育背景：

2022.09-2026.07　南开大学　计算机学院　　计算机科学与技术　　学士